

复杂系统的优化建模与预测分析

摘要

问题重述。核心问题和约束条件；明确决策变量、目标函数和可行域。

建模方法的独特性。简要说明模型类别（如微分方程、优化、随机模拟）以及相对于现有方法的独特假设或创新点。

核心算法逻辑。概述求解流程：输入、主要迭代或递推过程以及输出指标；如相关，请注明所使用的软件/算法（如 Gurobi、蒙特卡洛）。

最具影响力的定量结论。给出具体的数值结果和政策启示（如“成本降低 15.4%”或“服务水平超过 98%”）；避免模糊措辞。可选择性地陈述敏感性或稳健性分析结果。

以上四个模块使用加粗术语和短段落，便于模块化快速浏览，段落间距清晰。、对于论文的题目，叫 DNA 不错

只要前两问妥善完成，对于第三问，就可以单独开上下文，最难的部分就解决了，第三天只要针对第三问完成，最后一天对论文进行优化以及更优模型的引进。

最后的符号总计单独完完成，启用一次 max mode 即可

Keywords: 数学建模; 敏感性分析; AI 工具使用声明。

目录

1	引言	3
1.1	研究背景与动机	3
1.2	文献综述	3
1.3	问题重述	3
2	假设与符号	4
2.1	基本假设	4
2.2	符号定义	4
3	数据来源	6
3.1	数据描述与任务 DNA 来源	6
4	模型构建与实现	6
4.1	职业选择作为建模决策	6
4.1.1	基于 O*NET 的职业特征参数客观化	7
4.2	职业演化的模型选择	9
4.2.1	未来演化的可计算定义	10
4.2.2	模型框架选择与理由	10
4.3	任务层动态预测模型 (Task-first)	10
4.3.1	任务权重 (Task DNA) 与任务净冲击	10
4.3.2	将“发展轨迹”与“任务需求”紧密耦合：采纳混合机制	10
4.4	来自权威报告的 GenAI 能力维度评分：量表定义与证据叙述	11
4.4.1	量表定义	11
4.5	任务影响的权威评估驱动重标记：从关键词标签到能力维度分配	12
4.6	将任务 DNA 聚合为职业级冲击参数：软件开发人员	13
4.6.1	Top- N 可用性与聚合	13
4.6.2	可解释性分解：Top- K 贡献下界	13
4.6.3	最小校准：带有限人工审查的类别默认值	13
5	权威重标记后的机制力量检验与职业级聚合（软件开发人员）	13
5.1	职业级冲击聚合值	14
5.2	诊断：异质性与有效多样性	14
5.3	工程阈值与行动 ($E(t)$ 前的门控)	14
6	一致性检验与演化方程的实例化：软件开发人员的 $(\alpha, \beta, \mu_{occ})$	14
6.1	聚合值与一致性检验	15
6.2	机制力量（异质性）检验：无得分坍缩	15
6.3	低置信度任务的最小敏感性（上界论证）	15
6.4	修正 μ_{occ} 后进入职业演化	15

7 任务级功能需求模型与职业重新定义	16
7.1 任务级功能需求模型（替代职业级岗位需求）	16
7.1.1 建模目标与符号	16
7.1.2 双渠道动力学：自动化与规模化	16
7.1.3 采纳情景 $A(t)$	17
7.1.4 职业重新定义触发器（工作本质变化）	17
7.1.5 计算算法（可重现流程）	18
7.1.6 参数表（待实例化）	18
7.2 可视化方案	18
7.2.1 任务 DNA 与权威 s,c 分布（三职业）	19
7.2.2 图表模板	19
7.3 敏感性与稳健性	20
7.3.1 低置信度任务敏感性	20
7.3.2 关键参数敏感性	20
7.4 输出摘要模板（每个职业）	21
8 仿真结果与敏感性分析	21
8.1 职业选择的剪枝敏感性检验	21
9 讨论：优势与不足	24
9.1 优势	24
9.2 不足	24
10 结论	24
Appendices	26
附录 A Python 实现代码	26

1 引言

1.1 研究背景与动机

生成式人工智能 (Gen-AI) 正从一种小众的辅助工具演变为各行各业不可或缺的基础资源。随着其能力的指数级增长, Gen-AI 不仅在优化工作流程, 更在从根本上重塑劳动力市场的任务结构。面对这一激进的技术变革, 高等教育机构 (包括综合性大学、职业技术学院及艺术学院) 面临着前所未有的挑战: 如何调整人才培养模式, 以确保其毕业生在被 AI 环绕的未来职场中具备持久的竞争力和适应力?

1.2 文献综述

引用现有研究以增强模型的可信度。[4]

1.3 问题重述

第一部分 (职业层面: Gen-AI 影响下的“未来演化”) 赛题要求我们从 **STEM**、**技工/职业教育 (Trade)**、**艺术 (Arts)** 三个类别中各选一个具体职业, 并基于可追溯的数据与引用资料, 刻画这些职业在“Gen-AI 普及背景下”的未来变化。这里的“未来”应当被理解为一个明确的预测窗口内 (例如未来若干年) 职业形态的演化: 包括工作内容与岗位需求可能被削减、保持稳定或扩张的方向与幅度; “当前轨迹”可解释为 Gen-AI 在该行业中的渗透与使用正在沿着怎样的趋势推进; “预期影响”则指这种渗透对岗位结构与从业者工作方式带来的可度量变化。所有判断需要说明所用数据来源, 并解释我们认为会推动职业变化的关键驱动因素。

第二部分 (教育项目层面: 对三个具体院校项目给出可操作建议) 在完成职业层面的分析后, 赛题进一步要求: 为每个职业各选定一个“对应的具体院校与具体项目” (分别来自大学、技校/学徒体系、艺术院校), 并把建议落到这三个项目的管理决策上。建议至少需要覆盖两类核心问题: 一是项目规模是否应随职业变化而扩张或收缩 (以及扩张时如何吸引更多学生、收缩时如何在校内用其他项目吸纳潜在学生); 二是项目应当“教什么、如何处理 Gen-AI 的使用”, 例如禁止、有限允许、或纳入课程与训练体系等不同策略。这里“最好支持/最好准备”应被理解为: 对项目决策者给出**可落地且可比较**的方案, 并用数学模型的输出为这些方案提供证据链, 而不是停留在原则性口号。

第三部分 (评价口径层面: 不止“可就业”, 以及建议的外推边界) 赛题提醒“毕业生可就业性”可能不是衡量政策成功的唯一标准, 因此需要团队自行提出并论证额外的评价维度, 并说明当这些维度被纳入后, 结论与建议会如何改变。为避免概念含混, “可就业性”可被理解为毕业生在 Gen-AI 广泛存在的就业市场中获得并维持岗位的能力表现; 而“其他因素”则可包括但不限于: 教学与使用 Gen-AI 的资源消耗代价 (能耗/用水) 以及学术与创作场景中的归因与诚信风险等。最后, 若团队认为对某一院校/项目的建议可以推广到其他机构或项目, 需要明确写出可推广的条件与边界, 说明哪些情形下外推成立、哪些情形下不成立。

2 假设与符号

2.1 基本假设

2.2 符号定义

本文使用的所有符号定义如下表所示。

表 1: 本文使用的符号定义

符号	描述	定义域/单位
基本索引		
i	职业索引	$\mathbb{Z}^+$
j	任务索引	$\mathbb{Z}^+$
t	时间	年
N	可用任务数量	$\mathbb{Z}^+$
职业选择与特征空间		
x	候选职业	—
$f(x)$	职业特征向量 ($digit(x)$, $physical(x)$, $iprisk(x)$)	$[0, 1]^3$
$digit(x)$	数字化程度	$[0, 1]$
$physical(x)$	物理锚定程度	$[0, 1]$
$iprisk(x)$	知识产权/署名风险	$[0, 1]$
$D(x)$	数据可用性得分	$[0, 1]$
$\Delta(x_i, x_j)$	机制对比距离: $\ f(x_i) - f(x_j)\ _2$	$\mathbb{R}_{\geq 0}$
λ	职业选择中的权衡系数	无量纲
$v_m(x)$	职业 x 在 O*NET 描述符 m 下的原始评分	$[0, 100]$
$z_m(x)$	最小-最大归一化评分	$[0, 1]$
任务权重与影响参数		
w_{ij}	任务 j 在职业 i 中的权重; $\sum_j w_{ij} = 1$	$[0, 1]$
$w_{ij}(0)$	基线任务权重 (初始时刻)	$[0, 1]$
$w_{ij}(t)$	时变任务劳动份额 (任务结构)	$[0, 1]$
s_{ij}	任务 j 的替代分数 (GenAI 减少人力努力的程度)	$\{0.25, 0.5, 0.75\}$
c_{ij}	任务 j 的增强分数 (GenAI 扩展功能需求的程度)	$\{0.25, 0.5, 0.75\}$
α_i	职业级替代效应: $\sum_j w_{ij}s_{ij}$	$[0, 1]$
β_i	职业级增强效应: $\sum_j w_{ij}c_{ij}$	$[0, 1]$
μ_i	职业净冲击: $\beta_i - \alpha_i$	$[-1, 1]$
$\bar{c}_i$	职业增强潜力: $\sum_j w_{ij}(0)c_{ij}$	$[0, 1]$

续下页

表 1 – 续

符号	描述	定义域/单位
职业演化动力学		
$E_i(t)$	职业 i 在时刻 t 的就业需求	岗位数
$A(t)$	GenAI 采纳轨迹（情景族：快速/中速/慢速）	$[0, 1]$
g_i	职业 i 的非 AI 基线增长率	年 ⁻¹
k	采纳曲线陡峭程度参数	> 0
t_0	采纳曲线拐点时间（50% 采纳）	年
任务级功能需求模型		
$Q_i(t)$	职业 i 的整体功能输出需求指数	无量纲
$\ell_{ij}(t)$	任务 j 的劳动强度（单位输出的人力努力）	无量纲
$D_{ij}(t)$	任务 j 的人力劳动需求指数	无量纲
κ_s	替代速度系数	> 0
κ_c	增强对需求的放大因子	≥ 0
职业重新定义触发器		
$M_{\text{drop}}(t)$	消亡质量（需求降至可忽略的任务的基线权重总和）	$[0, 1]$
ε	”可忽略任务” 阈值（如 0.05 表示基线的 5%）	$(0, 1)$
θ	触发职业重新定义的消亡质量阈值	$(0, 1)$
δ	任务份额漂移阈值（Jensen–Shannon 散度）	> 0
t^*	职业重新定义触发时间	年
$\text{JS}(\cdot\ \cdot)$	Jensen–Shannon 散度	$[0, 1]$
机制力量诊断		
$\text{Var}_w(s)$	替代分数的加权方差： $\sum_j w_j (s_j - \alpha)^2$	$\mathbb{R}_{\geq 0}$
$\text{Var}_w(c)$	增强分数的加权方差： $\sum_j w_j (c_j - \beta)^2$	$\mathbb{R}_{\geq 0}$
$h_s(g)$	替代分数层级 g 的权重质量	$[0, 1]$
$h_c(g)$	增强分数层级 g 的权重质量	$[0, 1]$
$m(d)$	能力维度 d 的权重质量	$[0, 1]$
$\varepsilon_s, \varepsilon_c$	最小方差阈值（默认 0.005）	$\mathbb{R}_{>0}$
η_s, η_d	最大集中度阈值（默认 0.70, 0.60）	$(0, 1)$
权威重标记流程		
dim_j	映射到任务 j 的能力维度集	集合
d	能力维度索引（如代码生成、调试、测试等）	—
S_d	维度 d 的替代层级	$\{0.25, 0.5, 0.75\}$
C_d	维度 d 的增强层级	$\{0.25, 0.5, 0.75\}$

续下页

表 1 – 续

符号	描述	定义域/单位
$\text{sim}(j, d)$	任务 j 与维度 d 之间的语义相似度	$[0, 1]$
τ	语义匹配阈值	$[0, 1]$
π_{jd}	任务 j 到维度 d 的分配权重	$[0, 1]$
任务 DNA 字段 (O*NET 数据)		
Task_j	任务陈述文本	文本
IM_j	任务重要性评分	$[0, 100]$
FR_j	任务频率评分	$[0, 100]$
$\tilde{w}_j$	未归一化权重: $\text{IM}_j \cdot \text{FR}_j$	$\mathbb{R}_{\geq 0}$
SOC	O*NET-SOC 职业代码	代码

3 数据来源

3.1 数据描述与任务 DNA 来源

我们从 O*NET 30.1 文本数据库中提取各职业的任务陈述和任务评分，并根据重要性 (IM) 和任务频率 (FT) 评分计算任务权重。[7]

表 2: 任务 DNA 的数据来源与变量

变量/数据	描述	来源
O*NET 任务陈述	各职业的任务文本和标识符	O*NET 30.1 数据库 [7]
O*NET 任务评分 (IM, FT)	用于计算任务权重的重要性和频率评分	O*NET 30.1 数据库 [7]
任务 DNA CSV	包含 IM、FR、权重和基于规则的 s/c 的处理后任务表	基于 O*NET 30.1 衍生 [7]

4 模型构建与实现

4.1 职业选择作为建模决策

问题的前提要求从 STEM、技工和艺术领域各选择一个职业。我们没有将这一步骤视为临时假设 (主观选择)，而是明确地将职业选择建模为一个优化问题。这确保了后续关于 AI 驱动影响和教育建议的分析建立在可重现且数据驱动的框架之上。职业选择的核心目标不是所有职业的代表性，而是解释性对比。具体而言，三个职业的任务结构应当在与 GenAI 的交互方式上存在显著差异。除了机制对比外，问题还明确强调数据驱动的推理以及后文的政策建议。因此，所选职业同时需要有完备的数据支撑以及政策相关性。

4.1.1 基于 O*NET 的职业特征参数客观化

为避免职业特征参数 $digit(x)$ 、 $physical(x)$ 和 $iprisk(x)$ 的主观赋值，我们采用美国劳工部维护的 O*NET 职业数据库作为统一数据源。O*NET 基于专家调查和从业者反馈，为每个职业提供大量数值量表描述符，大多数指标自然地给出在 0–100 之间的实数上，适合直接用于定量建模。

我们不试图为每个维度找到“唯一正确”的指标，对于每个特征轴，我们选择少量语义上直接对应且可下载的 O*NET 描述符，并将其用作该轴的代理变量。对于没有描述（descriptor 字段缺失）的职业直接剔除。基于问题陈述和数据可用性约束，我们识别出三个主导维度，这些维度控制着 AI 影响在各职业间的异质性：

- **数字化程度** $digit(x)$ ：核心任务可以以数字方式表示、自动化或增强的程度；
- **物理锚定** $physical(x)$ ：任务执行对现场物理存在或与环境的手动交互的依赖程度；
- **知识产权和署名风险** $iprisk(x)$ ：价值创造对作者身份、原创性和所有权的敏感程度。

每个候选职业 x 由一个归一化的三维特征向量表示

$$f(x) = (digit(x), physical(x), iprisk(x)) \in [0, 1]^3, \quad (1)$$

其中较高的值表示相应特征的存在更强。

$$x_S \in STEM, \quad x_T \in Trades, \quad x_A \in Arts.$$

为衡量三种职业在特征空间中的异质性，我们用三点在三维空间中所形成三角形的面积作为衡量标准，定义为

$$Area3D(x_S, x_T, x_A) = \frac{1}{2} \|(f(x_T) - f(x_S)) \times (f(x_A) - f(x_S))\|_2,$$

我们以最大化该三角形面积为目标，形式化为

$$\max_{x_S \in S, x_T \in T, x_A \in A} Area3D(x_S, x_T, x_A).$$

此外，为便于后续可视化表达，定义其在二维投影下的面积为

$$Area2D_\pi(x_S, x_T, x_A) = \frac{1}{2} |\det([\pi(f(x_T)) - \pi(f(x_S)), \pi(f(x_A)) - \pi(f(x_S))])|,$$

其中 $\pi(\cdot)$ 表示三维特征到二维空间的投影映射。

归一化与可重现性 对于每个职业 x ，令 $v_m(x)$ 表示其在 O*NET 描述符 m 下的原始评分（0–100）。我们在整个职业集上应用最小-最大归一化：

$$z_m(x) = \frac{v_m(x) - \min_y v_m(y)}{\max_y v_m(y) - \min_y v_m(y)} \in [0, 1], \quad (2)$$

并对同一特征轴下的多个描述符取等权平均，得到 $digit(x)$ 、 $physical(x)$ 和 $iprisk(x)$ 。该过程完全基于公开可用数据和明确规则，确保参数值的可重现性和可审计性。

我们可视化了三维异质性及其二维投影，以验证所选职业在特征空间中占据不同区域（图 1 和图 2）。




图 1: 基于 O*NET 描述符（全局归一化）的全体职业三维异质性点云与最优三角面（strict 映射）。

我们先在全点云上求解无约束的最大面积三角形，随后根据赛题要求加入“STEM/技工/艺术三域各取一职”的约束，在可行域内重新最优化，得到约束后的最优三点：STEM（Robotics Engineers）、技工/Trades（First-Line Supervisors of Mechanics, Installers, and Repairers）与艺术/媒体（Court Reporters and Simultaneous Captioners）。其三角形面积为 0.262221，最短边长为 0.751378，该约束最优结果刻画三域职业在三维特征空间上的最大异质性跨度。




图 2: 全体职业异质性空间的二维投影与最优三点标注 (strict 映射, 全局归一化)。

表 3: 最大三角形面积解中三域 (STEM、技工、艺术) 所选代表职业与 O*NET-SOC 代码。三个点分别代表在三维特征空间选出的异质性最大化顶点, 即模型异质性指标的最优解。

领域	O*NET-SOC 代码	职业名称	3D 最大面积解中的角色
STEM	17-2199.08	Robotics Engineers	最优三角形顶点 (S)
Trade	49-1011.00	First-Line Supervisors of Mechanics, Installers, and Repairers	最优三角形顶点 (T)
Arts	27-3092.00	Court Reporters and Simultaneous Captioners	最优三角形顶点 (A)

三种职业均包含于官方对三个领域的定义 [6]。

稳健性证据与数值结果 为验证最大异质性三角形选取结果的稳健性, 我们在不同参数设置与采样条件下均重复求解, 并发现核心指标高度一致。具体地, 基于严格映射与全局归一化方法, 三维最大面积三角形的面积为

$$\text{Area}_{3D} = 0.262221$$

最短边长为

$$\text{min_edge_length} = 0.751378$$

进一步, 在不同采样规模 $M \in \{200, 400, 800\}$ 下, 最优三角形面积的相对差异均为 0.0%, 表明所建模型和结论具备高度的鲁棒性与可重复性。

4.2 职业演化的模型选择

问题的第二个核心要求是构建一个数据驱动的未来演化模型, 并明确说明“当前轨迹 (current trajectory)”以及会因 GenAI 而发生变化的驱动因素。在我们框架中, 预测对象不直接设为“职业岗位数”, 而是设为**职业内部的任务需求结构**: 即在给定 GenAI 采纳轨迹下, 各任务在职业内的重要性 (或相对需求) 如何随时间变化。因此, 我们首先构建 Task DNA 的任务权重 w_{ij} , 并以权威来源重标注任务级替代/增强强度 (s_{ij}, c_{ij}) , 进而得到任务级净冲击

$$\mu_{ij}^{\text{task}} = c_{ij} - s_{ij}, \quad (3)$$

并将“当前轨迹”形式化为外生采纳路径 $A(t) \in [0, 1]$ (快速/中速/慢速情景), 用于驱动任务需求随时间的演化。

4.2.1 未来演化的可计算定义

为消除题目中“future”的时间模糊性, 我们将未来定义为**任务层面的可计算事件**: 当某个关键任务在职业内的相对需求(份额)下降至一个足够小的阈值 ϵ 以下时, 即认为该任务在可操作意义上“趋近于消失”。具体地, 若 $p_{ij}(t)$ 表示职业 i 中任务 j 在时刻 t 的相对需求份额(定义见后文), 则定义任务 j 的“有效归零时间”为

$$\tau_{ij}(\epsilon) = \min\{t : p_{ij}(t) \leq \epsilon\}. \quad (4)$$

该定义可直接用于回答“未来何时发生显著变化”的问题, 并允许通过不同 ϵ 取值进行敏感性分析。

4.2.2 模型框架选择与理由

我们采用一个以任务为核心的最小化框架: (1) 职业由任务集合组成, 任务具有可从 O*NET 复现的权重; (2) GenAI 的影响在任务级体现为替代/增强(互补)强度; (3) “当前轨迹”由采纳路径 $A(t)$ 表示, 采纳越深, 任务级冲击释放越充分。该框架直接对应任务分解视角下的技术冲击机制(技术以任务为单位改变工作内容), 并避免对“职业岗位数”做强外推。

4.3 任务层动态预测模型 (Task-first)

在上述论证之后, 我们给出任务层预测的数学公式。模型包含两类输入: **任务结构**(来自 O*NET 任务数据)与**发展轨迹**(GenAI 采纳路径 $A(t)$)。预测输出为: 每个职业内部任务的相对需求演化 $p_{ij}(t)$, 以及“有效归零时间” $\tau_{ij}(\epsilon)$ 。

4.3.1 任务权重 (Task DNA) 与任务净冲击

设职业 i 由任务 $j = 1, \dots, J_i$ 组成, 权重为 w_{ij} , 满足

$$\sum_{j=1}^{J_i} w_{ij} = 1. \quad (5)$$

其中 w_{ij} 由 O*NET 任务重要度与频率评分构造并归一化 (Top- N 任务内再归一化), 确保可复现。

对于每个任务 j , 令 $s_{ij} \in [0, 1]$ 表示替代强度, $c_{ij} \in [0, 1]$ 表示增强(互补)强度。我们将任务层净冲击定义为

$$\mu_{ij}^{task} = c_{ij} - s_{ij}. \quad (6)$$

$\mu_{ij}^{task} > 0$ 表示 GenAI 更可能增强该任务(提高产出/质量/速度), $\mu_{ij}^{task} < 0$ 表示该任务更可能被替代或显著压缩。

4.3.2 将“发展轨迹”与“任务需求”紧密耦合: 采纳混合机制

题目要求“given the current trajectory and expected impacts of Gen-AI”, 其中“current trajectory”可操作地对应为**采纳程度随时间的扩散**。我们用外生的采纳路径 $A(t) \in [0, 1]$ 表示在时间 t 已采纳 GenAI

的工作流占比（或强度）。直观上：在 $A(t) = 0$ 时，任务结构保持基线；在 $A(t)$ 增大时，任务层净冲击 μ_{ij}^{task} 逐步释放，任务需求结构随之重排。

为避免凭空设定“绝对任务需求”的总量，我们以任务**相对需求权重**作为预测对象，并采用“采纳者/未采纳者混合”的最小机制：未采纳部分保持基线权重 w_{ij} ；采纳部分对任务权重施加与 μ_{ij}^{task} 单调一致的乘性变换（保证权重为正）。定义未归一化任务权重

$$q_{ij}(t) = w_{ij} \left[(1 - A(t)) + A(t) \exp(\eta \mu_{ij}^{task}) \right], \quad (7)$$

其中 $\eta > 0$ 为冲击强度缩放（无量纲），用于刻画“单位采纳带来的任务结构重排幅度”，并在敏感性分析中报告其影响。

将 $q_{ij}(t)$ 归一化得到任务相对需求份额

$$p_{ij}(t) = \frac{q_{ij}(t)}{\sum_{k=1}^{J_i} q_{ik}(t)}. \quad (8)$$

该定义保证 $\sum_j p_{ij}(t) = 1$ ，从而直接刻画职业内部任务结构如何随采纳轨迹而演化。

解释性 当 $A(t)$ 上升（GenAI 扩散加深）时，若 $\mu_{ij}^{task} < 0$ ，则 $q_{ij}(t)$ 相对缩小， $p_{ij}(t)$ 下降；反之若 $\mu_{ij}^{task} > 0$ ，则该任务份额上升。因此， $A(t)$ 将“发展轨迹”以严格数学方式映射为任务层需求结构的时间变化，从而满足题面关于“当前轨迹 + 预期影响”的建模要求。

未来时间点 结合前述定义，任务的有效归零时间仍为

$$\tau_{ij}(\epsilon) = \min\{t : p_{ij}(t) \leq \epsilon\}. \quad (9)$$

通过对 Top 任务的 $\tau_{ij}(\epsilon)$ 进行比较，我们可以直接回答：在不同采纳情景下，哪些任务会最先“消失”，哪些任务会长期保留，从而给出对该职业“未来”形态变化的可解释预测。

4.4 来自权威报告的 GenAI 能力维度评分：量表定义与证据叙述

为取代主观的“关键词标签”方法，我们采用来自权威评估和官方技术报告的能力评分。这些评分量化了 GenAI 在主要软件开发任务维度上的**替代**和**增强**能力，为将软件开发人员任务 DNA 映射到 (s, c) 输入提供可审计的依据。

4.4.1 量表定义

我们使用三个级别（低/中/高）表示 GenAI 能力，编码为 0.25、0.50 和 0.75：

- **低 (0.25)**: GenAI 在该任务类型上的自主能力有限，无法在没有人工干预的情况下可靠地交付满意结果；只能替代一小部分工作，但在人工监督下仍可提供协助。
- **中 (0.50)**: GenAI 表现中等，完成部分任务或提供有用建议，但仍需人工审查和协作；无法独立替代人工执行。

- **高 (0.75):** GenAI 表现强劲, 在许多子任务上接近专业人类水平; 在适当约束和验证下, 可处理大部分工作流程并提供显著增强, 但仍不完美。

注意: 0.25/0.50/0.75 的值是粗略的建模编码而非精确测量。所有级别都基于过去两年内发布的公开报告和对比实验。

表 4: 来自权威评估报告的 GenAI 能力维度标尺 (用于将软件开发人员任务映射到 s/c)

任务类型	替代得分	增强得分	主要证据和支持
代码生成	高 (0.75)	高 (0.75)	GPT-4 在 HumanEval 上达到 67.0% pass@1 [8]。 Claude 2 达到 71.2% [2]。
测试与验证	中 (0.50)	高 (0.75)	Google 报告约 25% 的新代码由 AI 生成 [9]。 LLM 生成的单元测试可达到有竞争力的覆盖率和可读性。 研究表明在静态分析引导下测试质量更高 [1]。
调试与错误修复	低 (0.25)	中 (0.50)	仍需人工审查, 因此替代保持中等。 Microsoft Research 报告即使有调试工具, 端到端调试成功率低于 50% (最佳模型 48.4%) [9]。
系统设计	低 (0.25)	中 (0.50)	提示修复建议有帮助, ”自我调试” 可提高准确率最多 12 个百分点 [3]。 复杂架构需要综合推理; 当前 GenAI 通常产生部分解决方案 [8]。 直接定量基准有限, 但模型可以协助起草和文档以加速设计讨论 [5]。
需求分析	低 (0.25)	中 (0.50)	模型在 NL→spec 任务上的提升有限 (如 Spider 上 2–3%) [3]。 然而, 总结和问题生成可以提高需求获取和分析效率 [8]。
用户沟通与文档	中 (0.50)	高 (0.75)	Claude 2 等模型可以高效生成长篇结构化文档并回答常见问题 [2]。 准确性仍是问题; 关键内容仍需人工验证 [8]。

4.5 任务影响的权威评估驱动重标记: 从关键词标签到能力维度分配

为提高任务影响参数 (s_{ij}, c_{ij}) 的可辩护性和可重现性, 我们放弃主观关键词标签, 采用”**权威评估** → **能力维度** → **语义匹配** → **分段分配**”的重标记工作流。核心思想是从官方评估报告中提取一组能力维度 (如代码生成、调试、测试/验证、需求分析、系统设计、文档/沟通) 的替代/增强级别, 将每个软件开发人员任务映射到 1–2 个能力维度, 然后在离散网格上分配 (s_j, c_j)。

能力映射与可追溯性要求 对于每个任务 j , 定义其映射的能力集 dim_j (通常为 1–2 个维度以保持可解释性)。任务级替代和增强在离散量表上分配:

$$s_j, c_j \in \{0.25, 0.5, 0.75\}. \quad (10)$$

为满足”数据驱动”审计标准，每个任务必须携带**可追溯链**：(i) 映射的能力维度 dim_j ，(ii) 至少一个权威来源链接，(iii) 任务到维度匹配逻辑的简要说明。这确保 (s_j, c_j) 是可审查的而非基于研究者直觉。

语义阈值、异常报告与有限人工覆盖 由于语义匹配可能导致漏报和误报，匹配阈值被视为可控决策参数：阈值过高可能遗漏有效匹配；过低可能引入错误匹配。因此，重标记输出必须包含相似度得分和异常报告（如低相似度匹配、多维度分配冲突），并允许对少量语义模糊的高权重任务进行小规模人工覆盖列表。这保持了整体可重现性，同时防止少量错误标签偏移职业级聚合值 (α_i, β_i) 。

4.6 将任务 DNA 聚合为职业级冲击参数：软件开发人员

本节将软件开发人员任务 DNA 从任务级输入 (w_{ij}, s_{ij}, c_{ij}) 聚合为职业级冲击参数 $(\alpha_i, \beta_i, \mu_i)$ ，这将输入演化方程 $\frac{dE_i(t)}{dt} = E_i(t)(g_i + A(t)(\beta_i - \alpha_i))$ 。

4.6.1 Top- N 可用性与聚合

在实践中，O*NET 任务评分可能对某些任务缺失。因此我们采用”Top- N_i 可用任务”策略：对于职业 i ，我们只保留具有足够评分以构建权重的任务，并重新归一化使得 $\sum_{j=1}^{N_i} w_{ij} = 1$ 。职业级替代压力、增强收益和净方向定义为

$$\alpha_i = \sum_{j=1}^{N_i} w_{ij} s_{ij}, \quad \beta_i = \sum_{j=1}^{N_i} w_{ij} c_{ij}, \quad (11)$$

4.6.2 可解释性分解：Top- K 贡献下界

为增强可解释性，我们分解高权重任务的贡献。定义部分和

$$\alpha_i^{(K)} = \sum_{j \in \text{Top-}K} w_{ij} s_{ij}, \quad \beta_i^{(K)} = \sum_{j \in \text{Top-}K} w_{ij} c_{ij}. \quad (12)$$

对于当前可用的 Top-5 样本， $\sum_{j \in \text{Top-}5} w_{ij} = 0.360897$ ，部分贡献 $\alpha_i^{(5)} = 0.1804485$ 和 $\beta_i^{(5)} = 0.2153186$ ，表明高权重任务（通常是测试/维护/需求/协作）将主导聚合冲击。

4.6.3 最小校准：带有限人工审查的类别默认值

为避免重新收集数据，我们仅通过一小组任务类别校准 s/c ，同时保持任务列表和权重 w_{ij} 不变。令 $\kappa(j)$ 将每个任务映射到一个粗类别（如需求/利益相关者、编码/实现、测试/验证/安全、监控/运维），并带有默认 (s, c) 对。然后我们仅手动审查少量高权重任务并记录简要证据说明，在保持可重现性和透明性的同时提高 (α_i, β_i) 的可识别性。

5 权威重标记后的机制力量检验与职业级聚合（软件开发人员）

在将 (s_j, c_j) 从主观关键词标签升级为”权威评估 $\rightarrow$ 能力维度 $\rightarrow$ 语义匹配 $\rightarrow$ 分段分配”流程后，我们必须验证**机制力量**： (s_j, c_j) 的任务级异质性应足够充分，且任务权重 w_j 不应将 (α, β) 坍塌为单一默认驱动的结果。否则，即使是权威来源也会在演化模型中产生弱可识别性。

5.1 职业级冲击聚合值

对于可用任务集（大小为 N ，允许 $N < 20$ ），重新归一化使得 $\sum_{j=1}^N w_j = 1$ ，我们定义

$$\alpha = \sum_{j=1}^N w_j s_j, \quad \beta = \sum_{j=1}^N w_j c_j, \quad \mu_{\text{occ}} = \beta - \alpha. \quad (13)$$

5.2 诊断：异质性与有效多样性

(1) 加权方差（异质性）

$$\text{Var}_w(s) = \sum_{j=1}^N w_j (s_j - \alpha)^2, \quad \text{Var}_w(c) = \sum_{j=1}^N w_j (c_j - \beta)^2. \quad (14)$$

低方差表明得分压缩或映射规则过度收敛，削弱可识别性。

(2) 加权层级直方图（避免单层级主导） 令 $\mathcal{G}_{LMH} = \{0.25, 0.5, 0.75\}$ 。定义层级权重质量

$$h_s(g) = \sum_{j: s_j=g} w_j, \quad h_c(g) = \sum_{j: c_j=g} w_j, \quad g \in \mathcal{G}_{LMH}. \quad (15)$$

较大的 $\max_g h_s(g)$ 或 $\max_g h_c(g)$ 标志默认驱动的坍缩。

(3) 能力维度权重质量（避免权重集中） 对于每个任务 j ，令 dim_j 为其映射的维度集（1-2 个维度）。如果多重映射，令 π_{jd} 将任务 j 分配到维度 d ，满足 $\sum_{d \in \text{dim}_j} \pi_{jd} = 1$ 。维度权重质量为

$$m(d) = \sum_{j=1}^N w_j \pi_{jd}. \quad (16)$$

高 $\max_d m(d)$ 表明尽管名义覆盖广泛，但有效多样性低。

5.3 工程阈值与行动 ($E(t)$ 前的门控)

我们使用工程阈值作为门控，决定是否进入情景演化：

$$\text{Var}_w(s) \geq \varepsilon_s, \quad \text{Var}_w(c) \geq \varepsilon_c, \quad \max_g h_s(g) \leq \eta_s, \quad \max_d m(d) \leq \eta_d, \quad (17)$$

默认值为 $\varepsilon_s = \varepsilon_c = 0.005$ ， $\eta_s = 0.70$ ， $\eta_d = 0.60$ 。违反意味着高机制风险，需要在推进到情景驱动的 $E(t)$ 动力学之前，对层级划分或维度到 (s, c) 映射进行优化（无需改变 w_j ）。

6 一致性检验与演化方程的实例化：软件开发人员的 $(\alpha, \beta, \mu_{\text{occ}})$

在通过“权威评估 → 能力维度 → 语义匹配 → 离散层级 (s, c) ”对任务影响进行重标记后，我们将任务 DNA 聚合回职业级冲击参数 $(\alpha, \beta, \mu_{\text{occ}})$ 并首先进行一致性检验，防止下游动力学依赖于错误实现的净冲击项。

6.1 聚合值与一致性检验

根据定义,

$$\mu_{\text{occ}} = \beta - \alpha. \quad (18)$$

给定预览值 $\alpha = 0.379113$ 和 $\beta = 0.629112$, 我们必须有

$$\mu_{\text{occ}} = 0.629112 - 0.379113 = 0.249999. \quad (19)$$

然而, 预览 JSON 报告 $\mu_{\text{occ}} = 0.504112$, 这与模型定义相矛盾。因此, 在将 μ_{occ} 用作 $E(t)$ 的输入之前, 聚合输出必须明确声明 `mu_definition_occ` 并修正实现; 否则, 演化推断将系统性地产生偏差。

6.2 机制力量 (异质性) 检验: 无得分坍塌

使用加权方差

$$\text{Var}_w(s) = \sum_{j=1}^N w_j (s_j - \alpha)^2, \quad \text{Var}_w(c) = \sum_{j=1}^N w_j (c_j - \beta)^2, \quad (20)$$

预览报告 $\text{Var}_w(s) = \text{Var}_w(c) = 0.015608$, 超过工程阈值 (如 0.005)。这表明重标记的 (s, c) 保留了足够的异质性; 机制可识别性未被坍塌。

6.3 低置信度任务的最小敏感性 (上界论证)

对于低置信度匹配 (如 `task_id=21666`, 权重 $w = 0.05434$), 可通过最坏情况边界论证稳健性。由于层级为 $\{0.25, 0.5, 0.75\}$, 每任务层级最大摆动为 0.50 ($0.25 \leftrightarrow 0.75$), 因此

$$\Delta_{\max}(\alpha) \leq w \cdot 0.50 = 0.05434 \times 0.50 = 0.02717, \quad (21)$$

类似地 $\Delta_{\max}(\beta) \leq 0.02717$ 。两个轻量级情景 (删除该任务; 重映射到次优维度) 足以支撑可辩护的敏感性陈述。

6.4 修正 μ_{occ} 后进入职业演化

一旦 μ_{occ} 被修正, 演化方程变为

$$\frac{dE(t)}{dt} = E(t)(g + A(t)\mu_{\text{occ}}), \quad (22)$$

其中 $A(t)$ 是采纳情景 (快速/中速/慢速), g 是非 AI 基线 (公共趋势估计或在相对指数约定下设为 0)。相对尺度具有闭式解

$$\frac{E(t)}{E(t_0)} = \exp\left(\int_{t_0}^t (g + A(\tau)\mu_{\text{occ}}) d\tau\right). \quad (23)$$

因此, 在 μ_{occ} 定义一致且 $A(t)/g$ 明确指定之前, 我们不推进到 $E(t)$ 情景曲线, 避免不可计算的叙述。

7 任务级功能需求模型与职业重新定义

7.1 任务级功能需求模型（替代职业级岗位需求）

7.1.1 建模目标与符号

我们不预测职业级岗位数量，而是预测在 GenAI 采纳下职业的任务组成如何演化，以及与每个任务相关的人力劳动需求如何随时间变化。核心主张是，当一个职业的基线任务束中足够大的部分变得可忽略不计时，该职业的性质已经改变，应被重新定义（确切的新职位名称不是模型的核心）。

考虑一个职业 i 分解为任务 $j = 1, \dots, J_i$ 。对于每个任务，我们假设以下输入已经通过任务 DNA 和权威重标记流程构建完成：

- 基线任务权重 $w_{ij}(0)$ ，满足 $\sum_j w_{ij}(0) = 1$ 。
- 替代分数 $s_{ij} \in [0, 1]$ ：GenAI 能够在多大程度上减少任务 j 的人力努力。
- 增强分数 $c_{ij} \in [0, 1]$ ：GenAI 能够在多大程度上扩展与任务 j 相关的功能范围/需求。
- 采纳曲线 $A(t) \in [0, 1]$ ：时刻 t 的 GenAI 采纳比例/强度（情景驱动）。

我们引入四个状态变量：

$Q_i(t)$ ：职业 i 的整体功能输出需求指数，
 $\ell_{ij}(t)$ ：任务 j 的劳动强度（单位输出的人力努力），
 $w_{ij}(t)$ ：时变任务劳动份额（任务结构），
 $D_{ij}(t)$ ：任务 j 的人力劳动需求指数

直观上， s_{ij} 控制人力努力对任务变得不必要的速度（自动化渠道），而 c_{ij} 控制整体功能需求可以扩张的程度（规模化渠道）。这些是不同的机制，不会强制抵消。

7.1.2 双渠道动力学：自动化与规模化

(a) 自动化渠道：替代降低劳动强度。我们假设随着 GenAI 采纳增加，替代分数更高的任务每单位输出所需的人力努力更少：

$$\frac{d \ln \ell_{ij}(t)}{dt} = -\kappa_s A(t) s_{ij}, \quad \kappa_s > 0. \quad (24)$$

闭式解为

$$\ell_{ij}(t) = \exp\left(-\kappa_s s_{ij} \int_0^t A(\tau) d\tau\right). \quad (25)$$

参数含义（通俗语言）。 κ_s 是替代速度系数。更大的 κ_s 意味着在相同的 $A(t)$ 和 s_{ij} 下人力努力下降更快。

(b) 任务结构更新：职业内部重新分配。 自动化改变了职业的内部组成。我们形成未归一化份额并重新归一化：

$$\tilde{w}_{ij}(t) = w_{ij}(0) \ell_{ij}(t), \quad w_{ij}(t) = \frac{\tilde{w}_{ij}(t)}{\sum_k \tilde{w}_{ik}(t)}. \quad (26)$$

解释。高度自动化的任务（小的 $\ell_{ij}(t)$ ）失去份额；剩余的人力劳动转移到更难替代的任务。

(c) 规模化渠道（可选）：增强扩展整体功能需求。 为了捕捉生产力工具可能增加组织选择完成的工作总量这一可能性，我们建模整体功能需求指数：

$$\frac{d \ln Q_i(t)}{dt} = g_i + \kappa_c A(t) \bar{c}_i, \quad (27)$$

其中

$$\bar{c}_i = \sum_j w_{ij}(0) c_{ij}. \quad (28)$$

参数含义（通俗语言）。 g_i 是功能需求的基线（非 GenAI）增长；如果想避免宏观假设，可设 $g_i = 0$ 。 $\kappa_c \geq 0$ 是增强对需求的放大因子。 $\bar{c}_i$ 总结了职业在基线组成下的增强潜力。（一种变体用 $w_{ij}(t)$ 替代 $w_{ij}(0)$ ；我们使用 (28) 以简化和参数稳定性。）

(d) 任务劳动需求指数。 我们通过当前任务结构将功能需求分配给任务：

$$D_{ij}(t) = Q_i(t) w_{ij}(t), \quad \frac{D_{ij}(t)}{D_{ij}(0)} = \frac{Q_i(t) w_{ij}(t)}{w_{ij}(0)}. \quad (29)$$

解释。即使整体需求 $Q_i(t)$ 增长，如果任务份额 $w_{ij}(t)$ 因替代而崩溃，任务的人力需求仍可能缩减。

7.1.3 采纳情景 $A(t)$

我们使用简约、可解释的逻辑斯蒂族：

$$A(t) = \frac{1}{1 + \exp(-k(t - t_0))}. \quad (30)$$

参数含义（通俗语言）。 k 控制陡峭程度（采纳加速的速度）。 t_0 是拐点时间，此时采纳达到 50%。我们通过选择三对 (k, t_0) 定义三种情景（快速/中速/慢速）；这保持了驱动因子数量较少，同时支持敏感性比较。

7.1.4 职业重新定义触发器（工作本质变化）

我们通过任务消亡和任务结构漂移形式化“工作本质变化”。两个标准中任一标准均可触发重新定义。

(a) 消亡质量（任务需求变得可忽略不计）。 当任务的人力需求指数降至其基线的一小部分以下时，该任务被视为功能上可忽略不计：

$$\frac{D_{ij}(t)}{D_{ij}(0)} < \varepsilon, \quad (31)$$

其中 $\varepsilon \in (0, 1)$ (例如, $\varepsilon = 0.05$)。定义基线加权的消亡质量:

$$M_{\text{drop}}(t) = \sum_{j: D_{ij}(t)/D_{ij}(0) < \varepsilon} w_{ij}(0). \quad (32)$$

我们认为职业在本质上已改变, 当且仅当

$$M_{\text{drop}}(t) \geq \theta, \quad (33)$$

其中 $\theta \in (0, 1)$ (例如, $\theta = 0.30$) 是在触发重新定义之前必须变得可忽略不计的基线任务质量份额。

(b) 任务结构漂移 (分布变化)。即使没有许多任务完全变得可忽略不计, 如果职业的任务份额分布发生足够大的变化, 该职业也可能在性质上变得不同。令 $w_i(t)$ 表示向量 $(w_{i1}(t), \dots, w_{iJ_i}(t))$ 。我们使用 Jensen-Shannon 散度作为对称、有界的漂移度量:

$$\text{JS}(w_i(t) \parallel w_i(0)) \geq \delta, \quad (34)$$

其中 $\delta > 0$ 是为稳健性选择的保守阈值。

触发时间。定义

$$t^* = \inf \{t : M_{\text{drop}}(t) \geq \theta \text{ 或 } \text{JS}(w_i(t) \parallel w_i(0)) \geq \delta\}. \quad (35)$$

我们报告 t^* 是否存在于预测范围内, 并将其用作职业应被重新定义的基于模型的证据。

7.1.5 计算算法 (可重现流程)

对于每个职业 i 和每个采纳情景:

1. 从 (30) 计算 $A(t)$, 以及累积采纳积分 $I(t) = \int_0^t A(\tau) d\tau$ (数值求积)。
2. 使用 (25) 计算劳动强度 $\ell_{ij}(t)$ 。
3. 通过 (26) 更新任务份额 $w_{ij}(t)$ 。
4. 使用 (27) 求解 $Q_i(t)$ 。如果避免宏观假设, 设 $g_i = 0$ 和 $\kappa_c = 0$, 使得 $Q_i(t) \equiv 1$ 。
5. 从 (29) 计算任务劳动需求指数 $D_{ij}(t)$ 。
6. 评估重新定义标准 (33) 和 (34), 如果存在则通过 (35) 获得 t^* 。

7.1.6 参数表 (待实例化)

表 5 总结了需要指定的参数。我们优先考虑可解释性和低驱动因子数量。

7.2 可视化方案

本节定义展示任务结构变化和重新定义证据所需的图表。

表 5: 任务级模型参数及通俗语言含义。

参数	典型范围/设置	含义（通俗语言）
k, t_0	情景特定	采纳速度和 50% 采纳时间
κ_s	> 0	替代降低人力努力的速度
g_i	0（默认）	基线功能需求增长（非 GenAI）
κ_c	0 或 > 0	增强扩展总需求的强度
ε	例如 0.05	”可忽略任务” 阈值（基线的 5%）
θ	例如 0.30	重新定义职业所需的消亡质量
δ	例如 0.10–0.30	任务份额漂移阈值（JS 散度）

7.2.1 任务 DNA 与权威 s, c 分布（三职业）

为确保任务级建模输入可追溯，我们展示三职业的基线任务权重分布（IM–FR 散点，点面积为 w ）以及权威重标注后的 s, c 档位分布。这些图表对应已确认的三条职业：17-2199.08（机器人工程师）、49-1011.00（一线主管：机械/安装/维修）、27-3092.00（法庭速录与字幕）。相应图示见图 3–8。




图 3: 职业 17-2199.08 的任务 DNA 权重分布：IM–FR 散点图，点面积与 w 成正比。

职业 17-2199.08：机器人工程师。

职业 49-1011.00：一线主管（机械/安装/维修）。

职业 27-3092.00：法庭速录与字幕。

7.2.2 图表模板

图 1: 采纳情景 $A(t)$ 。




图 4: 职业 17-2199.08 的权威 s, c 档位分布。

图 2: 顶部任务的任务劳动需求轨迹。

图 3: 任务结构漂移 $w_{ij}(t)$ 。

图 4: 重新定义证据和触发时间 t^* 。

7.3 敏感性与稳健性

7.3.1 低置信度任务敏感性

由于与权威评估维度的语义匹配较弱, 某些任务可能具有低置信度的 (s_{ij}, c_{ij}) 分配。对于每个标记的任务, 我们运行两种有界敏感性情况:

- **删除:** 从集合中移除该任务, 并重新归一化剩余的 $w_{ij}(0)$ 。
- **重新标记:** 保持 $w_{ij}(0)$, 但用第二最佳可接受映射 (或保守界限) 替换 (s_{ij}, c_{ij}) 。

我们报告以下变化: (i) 重新定义是否在范围内发生, (ii) 触发时间 t^* , 以及 (iii) 消亡质量曲线 $M_{\text{drop}}(t)$ 。

7.3.2 关键参数敏感性

我们仅变化最小、高杠杆的参数集以避免过拟合:

- κ_s (替代速度): 慢速/中速/快速值。
- κ_c (规模化开/关): $\kappa_c = 0$ 与正值。




图 5: 职业 49-1011.00 的任务 DNA 权重分布: IM-FR 散点图, 点面积与 w 成正比。

- 阈值 $(\varepsilon, \theta, \delta)$: 保守与激进设置。

对于每种组合, 我们总结定性结论的稳定性 (哪些任务变得可忽略不计, 以及是否/何时触发重新定义)。

7.4 输出摘要模板 (每个职业)

对于每个职业和每个采纳情景, 我们呈现:

1. 任务需求结果: 按 $D_{ij}(15)/D_{ij}(0)$ 排名的任务列表, 突出显示低于 ε 的任务。
2. 任务结构变化: $w_{ij}(t)$ 的可视化以及漂移度量 $JS(w_i(t)||w_i(0))$ 。
3. 重新定义决策: (33) 或 (34) 中的标准是否满足, 以及触发时间 t^* (如适用)。

8 仿真结果与敏感性分析

8.1 职业选择的剪枝敏感性检验

在最大面积三角形搜索中, 穷举式遍历全体职业组合的计算复杂度为 $O(n^3)$, 其中 n 为职业总数。当 O*NET 数据库包含超过 1000 个职业时, 这一暴力枚举耗时过长、资源成本过高。为此, 我们采用“候选剪枝”策略: 对每个域 (STEM/技工/艺术) 分别选取距离本域中心最远的前 M 个职业, 加上每维特征轴上最极端的若干职业, 构成候选池, 仅在候选池内进行三重循环求解。




图 6: 职业 49-1011.00 的权威 s, c 档位分布。

检验方法 为验证剪枝不会遗漏真正的最优解，我们对候选规模 M 进行敏感性扫描。具体地，取 $M \in \{200, 400, 800\}$ 三档：

- $M = 200$ ：候选池较紧凑，计算效率最高；
- $M = 400$ ：候选池扩展一倍，覆盖更多边缘职业；
- $M = 800$ ：候选池接近全域职业规模，逼近全穷举。

检验结果 在三种候选规模下，最大面积三角形的求解结果如表 6 所示。

表 6: 候选规模敏感性检验：最优三角形在不同 M 下的求解结果

候选规模 M	三角形面积	最短边长	三点是否一致	面积差异
200	0.2622	0.7514	基准	—
400	0.2622	0.7514	一致	0%
800	0.2622	0.7514	一致	0%




图 7: 职业 27-3092.00 的任务 DNA 权重分布: IM-FR 散点图, 点面积与 w 成正比。




图 13: 候选规模 M 与最优三角形面积的关系 (strict 映射)。

三次求解均返回相同的职业组合:

- STEM: Robotics Engineers (17-2199.08)
- 技工: First-Line Supervisors of Mechanics, Installers, and Repairers (49-1011.00)




图 8: 职业 27-3092.00 的权威 s, c 档位分布。

图 9: 由 (30) 定义的 GenAI 采纳情景 $A(t)$ (快速/中速/慢速)。拐点时间 t_0 标记 50% 采纳。

- 艺术: Court Reporters and Simultaneous Captioners (27-3092.00)

稳健性判定 若相同的”职业三角”在全部三次测试中持续胜出，则证明结果是稳健（可靠）的，而非数学上的偶然现象。本检验中，面积差异为 0%，远低于 5% 的阈值标准，因此我们判定：

三职业配置对候选规模的选择具有稳健性。

这一结论意味着，即使将候选池从 200 扩大到 800，最优解依然不变，排除了因剪枝不足而遗漏更优解的可能。

9 讨论：优势与不足

9.1 优势

预测精度高；适用于高维数据。

9.2 不足

大规模矩阵的计算复杂度较高。

10 结论

总结研究发现并提供可操作的建议。

图 10: 职业 i 中基线权重最高的前 K 个任务在各采纳情景下的相对任务劳动需求轨迹 $D_{ij}(t)/D_{ij}(0)$ 。此图直接显示哪些任务变得可忽略不计, 哪些任务仍然核心。

图 11: 时变任务结构 $w_{ij}(t)$ (堆叠面积图或热图)。此图可视化由 (26) 驱动的对替代引起的职业内部重新分配。

参考文献

- [1] Nadia Alshahwan et al. Automated Unit Test Generation using Large Language Models at Meta. *arXiv preprint arXiv:2409.03093*, 2024. URL <https://arxiv.org/abs/2409.03093>. Accessed January 30, 2026.
- [2] Anthropic. Claude 2 Model Card, 2023. URL <https://www.anthropic.com/claude-2-model-card>. Accessed January 30, 2026.
- [3] Xinyun Chen, Maxwell Lin, Nathanael Schärli, and Denny Zhou. Teaching Large Language Models to Self-Debug. *arXiv preprint arXiv:2304.05128*, 2023. URL <https://arxiv.org/abs/2304.05128>. Accessed January 30, 2026.
- [4] Carl Benedikt Frey and Michael A. Osborne. The Future of Employment: How Susceptible are Jobs to Computerisation? Technical report, Oxford Martin School, University of Oxford, 2017. URL <https://www.oxfordmartin.ox.ac.uk/downloads/academic/future-of-employment.pdf>. Accessed January 30, 2026.
- [5] Google Research. Large Sequence Models for Software Development Activities. Google Research Blog, 2024. URL <https://research.google/blog/large-sequence-models-for-software-development-activities/>. Accessed January 30, 2026.
- [6] O*NET Resource Center. O*NET-SOC and SOC structure - Occupational Listings, 2019. URL <https://www.onetcenter.org/taxonomy/2019/structure.html>. Accessed January 31, 2026.
- [7] O*NET Resource Center. O*NET Database 30.1, 2025. URL <https://www.onetcenter.org/database.html>. Accessed January 30, 2026.
- [8] OpenAI. GPT-4 Technical Report. Technical report, 2023. URL <https://cdn.openai.com/papers/gpt-4.pdf>. Accessed January 30, 2026.
- [9] Kyle Wiggers. AI Models Still Struggle to Debug Software, Microsoft Study Shows. TechCrunch, 2025. URL <https://techcrunch.com/2025/04/10/ai-models-still-struggle-to-debug-software-microsoft-study-shows/>. Accessed January 30, 2026.

图 12: 随时间的重新定义证据: 消亡质量 $M_{\text{drop}}(t)$ 及阈值 θ , 以及 (可选) $\text{JS}(w_i(t) \| w_i(0))$ 及阈值 δ 。最早的交叉点在 (35) 中定义 t^* 。

Appendices

附录 A Python 实现代码

```
1 def model_solver(data):  
2     # 核心数学逻辑  
3     return results
```

AI 工具使用报告

1. 对话可追溯性

对于每次使用，提供准确的**提示词/查询**和**原始 AI 输出**（或具有代表性的摘录）。仅当 AI 仅用于翻译时才可省略完整日志；在这种情况下，需注明**工具名称和版本**。

- **示例—提示词：**”为模型部分建议一个大纲。” **输出（摘录）：**”1. 陈述假设；2. 定义符号；3. 推导主要方程...”
- **仅使用翻译的团队：**声明工具名称和版本（如 DeepL 4.2、ChatGPT-4）；无需提供完整的提示词日志。

2. 分阶段声明

说明 AI 在哪些阶段被使用，例如：

- 初始构思/头脑风暴
- 代码修正/调试
- 翻译/文字编辑

标注每个阶段是否使用，并注明每个阶段使用的工具。

3. 风险验证

描述团队如何检查**幻觉**和**错误引用**：例如，对关键声明进行人工事实核查、验证参考文献、交叉检验公式和代码。如果仅用于翻译，请声明没有将实质性技术内容委托给 AI 处理。