

复杂系统的优化建模与预测分析

摘要

问题重述。用一到两句话，用你自己的学术语言陈述**核心问题**和**约束条件**；明确**决策变量**、**目标函数**和**可行域**。

建模方法的独特性。简要说明**模型类别**（如微分方程、优化、随机模拟）以及相对于现有方法的**独特假设**或**创新点**。

核心算法逻辑。概述**求解流程**：输入、主要迭代或递推过程以及输出指标；如相关，请注明所使用的**软件/算法**（如 Gurobi、蒙特卡洛）。

最具影响力的定量结论。给出具体的**数值结果**和**政策启示**（如“成本降低 15.4%”或“服务水平超过 98%”）；避免模糊措辞。可选择性地陈述**敏感性**或**稳健性**分析结果。

以上四个模块使用加粗术语和短段落，便于模块化快速浏览，段落间距清晰。

Keywords: 数学建模; 敏感性分析; AI 工具使用声明。

目录

1	引言	3
1.1	研究背景与动机	3
1.2	文献综述	3
1.3	问题重述	3
2	假设与符号	4
2.1	基本假设	4
2.2	符号定义	4
3	数据来源	6
3.1	数据描述与任务 DNA 来源	6
4	模型构建与实现	6
4.1	职业选择作为建模决策	6
4.1.1	基于 O*NET 的职业特征参数客观化	7
4.1.2	所选职业的修订与最终配置	9
4.2	职业演化的模型选择	10
4.2.1	未来演化的可计算定义	10
4.2.2	候选建模方法比较	10
4.2.3	最终模型选择	11
4.3	职业演化的任务聚合动态模型	11
4.3.1	任务聚合与职业动力学	11
4.4	来自权威报告的 GenAI 能力维度评分：量表定义与证据叙述	12
4.4.1	量表定义	12
4.4.2	按任务类型的能力证据（叙述性论证）	12
4.5	任务影响的权威评估驱动重标记：从关键词标签到能力维度分配	13
4.6	将任务 DNA 聚合为职业级冲击参数：软件开发人员	14
4.6.1	Top- N 可用性与聚合	14
4.6.2	可解释性分解：Top- K 贡献下界	15
4.6.3	评分规则的有效性检验：避免近常数 s/c	15
4.6.4	最小校准：带有限人工审查的类别默认值	15
5	权威重标记后的机制力量检验与职业级聚合（软件开发人员）	15
5.1	职业级冲击聚合值	15
5.2	诊断：异质性与有效多样性	16
5.3	工程阈值与行动（ $E(t)$ 前的门控）	16
6	一致性检验与演化方程的实例化：软件开发人员的 (α, β, μ)	16
6.1	聚合值与一致性检验	16

6.2	机制力量（异质性）检验：无得分坍塌	17
6.3	低置信度任务的最小敏感性（上界论证）	17
6.4	修正 μ 后进入职业演化	17
7	任务级功能需求模型与职业重新定义	17
7.1	任务级功能需求模型（替代职业级岗位需求）	17
7.1.1	建模目标与符号	17
7.1.2	双渠道动力学：自动化与规模化	18
7.1.3	采纳情景 $A(t)$	19
7.1.4	职业重新定义触发器（工作本质变化）	19
7.1.5	计算算法（可重现流程）	20
7.1.6	参数表（待实例化）	20
7.2	可视化方案	20
7.2.1	图表模板	21
7.3	敏感性与稳健性	21
7.3.1	低置信度任务敏感性	21
7.3.2	关键参数敏感性	21
7.4	输出摘要模板（每个职业）	22
8	仿真结果与敏感性分析	22
9	讨论：优势与不足	22
9.1	优势	22
9.2	不足	22
10	结论	22
	Appendices	22
	附录 A Python 实现代码	22

1 引言

1.1 研究背景与动机

生成式人工智能 (Gen-AI) 正从一种小众的辅助工具演变为各行各业不可或缺的基础资源。随着其能力的指数级增长, Gen-AI 不仅在优化工作流程, 更在从根本上重塑劳动力市场的任务结构。面对这一激进的技术变革, 高等教育机构 (包括综合性大学、职业技术学院及艺术学院) 面临着前所未有的挑战: 如何调整人才培养模式, 以确保其毕业生在被 AI 环绕的未来职场中具备持久的竞争力和适应力?

AI 使用声明。 我们在本文中与文末的 **AI 工具使用报告** 中披露了 AI 工具的使用情况。

1.2 文献综述

引用现有研究以增强模型的可信度。[?]]

1.3 问题重述

第一部分 (职业层面: Gen-AI 影响下的“未来演化”) 赛题要求我们从 **STEM**、**技工/职业教育 (Trade)**、**艺术 (Arts)** 三个类别中各选一个具体职业, 并基于可追溯的数据与引用资料, 刻画这些职业在“Gen-AI 普及背景下”的未来变化。这里的“未来”应当被理解为一个明确的预测窗口内 (例如未来若干年) 职业形态的演化: 包括工作内容与岗位需求可能被削减、保持稳定或扩张的方向与幅度; “当前轨迹”可解释为 Gen-AI 在该行业中的渗透与使用正在沿着怎样的趋势推进; “预期影响”则指这种渗透对岗位结构与从业者工作方式带来的可度量变化。所有判断需要说明所用数据来源, 并解释我们认为会推动职业变化的关键驱动因素。

第二部分 (教育项目层面: 对三个具体院校项目给出可操作建议) 在完成职业层面的分析后, 赛题进一步要求: 为每个职业各选定一个“对应的具体院校与具体项目” (分别来自大学、技校/学徒体系、艺术院校), 并把建议落到这三个项目的管理决策上。建议至少需要覆盖两类核心问题: 一是项目规模是否应随职业变化而扩张或收缩 (以及扩张时如何吸引更多学生、收缩时如何在校内用其他项目吸纳潜在学生); 二是项目应当“教什么、如何处理 Gen-AI 的使用”, 例如禁止、有限允许、或纳入课程与训练体系等不同策略。这里“最好支持/最好准备”应被理解为: 对项目决策者给出**可落地且可比较**的方案, 并用数学模型的输出为这些方案提供证据链, 而不是停留在原则性口号。

第三部分 (评价口径层面: 不止“可就业”, 以及建议的外推边界) 赛题提醒“毕业生可就业性”可能不是衡量政策成功的唯一标准, 因此需要团队自行提出并论证额外的评价维度, 并说明当这些维度被纳入后, 结论与建议会如何改变。为避免概念含混, “可就业性”可被理解为毕业生在 Gen-AI 广泛存在的就业市场中获得并维持岗位的能力表现; 而“其他因素”则可包括但不限于: 教学与使用 Gen-AI 的资源消耗代价 (能耗/用水) 以及学术与创作场景中的归因与诚信风险等。最后, 若团队认为对某一院校/项目的建议可以推广到其他机构或项目, 需要明确写出可推广的条件与边界, 说明哪些情形下外推成立、哪些情形下不成立。

2 假设与符号

2.1 基本假设

2.2 符号定义

本文使用的所有符号定义如下表所示。

表 1: 本文使用的符号定义

符号	描述	定义域/单位
基本索引		
i	职业索引	$\mathbb{Z}^+$
j	任务索引	$\mathbb{Z}^+$
t	时间	年
N	可用任务数量	$\mathbb{Z}^+$
职业选择与特征空间		
x	候选职业	—
$f(x)$	职业特征向量 ($digit(x)$, $physical(x)$, $iprisk(x)$)	$[0, 1]^3$
$digit(x)$	数字化程度	$[0, 1]$
$physical(x)$	物理锚定程度	$[0, 1]$
$iprisk(x)$	知识产权/署名风险	$[0, 1]$
$D(x)$	数据可用性得分	$[0, 1]$
$\Delta(x_i, x_j)$	机制对比距离: $\ f(x_i) - f(x_j)\ _2$	$\mathbb{R}_{\geq 0}$
λ	职业选择中的权衡系数	无量纲
$v_m(x)$	职业 x 在 O*NET 描述符 m 下的原始评分	$[0, 100]$
$z_m(x)$	最小-最大归一化评分	$[0, 1]$
任务权重与影响参数		
w_{ij}	任务 j 在职业 i 中的权重; $\sum_j w_{ij} = 1$	$[0, 1]$
$w_{ij}(0)$	基线任务权重 (初始时刻)	$[0, 1]$
$w_{ij}(t)$	时变任务劳动份额 (任务结构)	$[0, 1]$
s_{ij}	任务 j 的替代分数 (GenAI 减少人力努力的程度)	$\{0.25, 0.5, 0.75\}$
c_{ij}	任务 j 的增强分数 (GenAI 扩展功能需求的程度)	$\{0.25, 0.5, 0.75\}$
α_i	职业级替代效应: $\sum_j w_{ij}s_{ij}$	$[0, 1]$
β_i	职业级增强效应: $\sum_j w_{ij}c_{ij}$	$[0, 1]$
μ_i	职业净冲击: $\beta_i - \alpha_i$	$[-1, 1]$
$\bar{c}_i$	职业增强潜力: $\sum_j w_{ij}(0)c_{ij}$	$[0, 1]$

续下页

表 1 – 续

符号	描述	定义域/单位
职业演化动力学		
$E_i(t)$	职业 i 在时刻 t 的就业需求	岗位数
$A(t)$	GenAI 采纳轨迹（情景族：快速/中速/慢速）	$[0, 1]$
g_i	职业 i 的非 AI 基线增长率	年 ⁻¹
k	采纳曲线陡峭程度参数	> 0
t_0	采纳曲线拐点时间（50% 采纳）	年
任务级功能需求模型		
$Q_i(t)$	职业 i 的整体功能输出需求指数	无量纲
$\ell_{ij}(t)$	任务 j 的劳动强度（单位输出的人力努力）	无量纲
$D_{ij}(t)$	任务 j 的人力劳动需求指数	无量纲
κ_s	替代速度系数	> 0
κ_c	增强对需求的放大因子	≥ 0
职业重新定义触发器		
$M_{\text{drop}}(t)$	消亡质量（需求降至可忽略的任务的基线权重总和）	$[0, 1]$
ε	”可忽略任务” 阈值（如 0.05 表示基线的 5%）	$(0, 1)$
θ	触发职业重新定义的消亡质量阈值	$(0, 1)$
δ	任务份额漂移阈值（Jensen–Shannon 散度）	> 0
t^*	职业重新定义触发时间	年
$\text{JS}(\cdot\ \cdot)$	Jensen–Shannon 散度	$[0, 1]$
机制力量诊断		
$\text{Var}_w(s)$	替代分数的加权方差： $\sum_j w_j (s_j - \alpha)^2$	$\mathbb{R}_{\geq 0}$
$\text{Var}_w(c)$	增强分数的加权方差： $\sum_j w_j (c_j - \beta)^2$	$\mathbb{R}_{\geq 0}$
$h_s(g)$	替代分数层级 g 的权重质量	$[0, 1]$
$h_c(g)$	增强分数层级 g 的权重质量	$[0, 1]$
$m(d)$	能力维度 d 的权重质量	$[0, 1]$
$\varepsilon_s, \varepsilon_c$	最小方差阈值（默认 0.005）	$\mathbb{R}_{>0}$
η_s, η_d	最大集中度阈值（默认 0.70, 0.60）	$(0, 1)$
权威重标记流程		
dim_j	映射到任务 j 的能力维度集	集合
d	能力维度索引（如代码生成、调试、测试等）	—
S_d	维度 d 的替代层级	$\{0.25, 0.5, 0.75\}$
C_d	维度 d 的增强层级	$\{0.25, 0.5, 0.75\}$

续下页

表 1 – 续

符号	描述	定义域/单位
$\text{sim}(j, d)$	任务 j 与维度 d 之间的语义相似度	$[0, 1]$
τ	语义匹配阈值	$[0, 1]$
π_{jd}	任务 j 到维度 d 的分配权重	$[0, 1]$
任务 DNA 字段 (O*NET 数据)		
Task_j	任务陈述文本	文本
IM_j	任务重要性评分	$[0, 100]$
FR_j	任务频率评分	$[0, 100]$
$\tilde{w}_j$	未归一化权重: $\text{IM}_j \cdot \text{FR}_j$	$\mathbb{R}_{\geq 0}$
SOC	O*NET-SOC 职业代码	代码

3 数据来源

3.1 数据描述与任务 DNA 来源

我们从 O*NET 30.1 文本数据库中提取 SOC 15-1252.00 的任务陈述和任务评分, 并根据重要性 (IM) 和任务频率 (FT) 评分计算任务权重。[?]]

表 2: 任务 DNA 的数据来源与变量

变量/数据	描述	来源
O*NET 任务陈述	SOC 15-1252.00 的任务文本和标识符	O*NET 30.1 数据库 [?]]
O*NET 任务评分 (IM, FT)	用于计算任务权重的重要性和频率评分	O*NET 30.1 数据库 [?]]
任务 DNA CSV	包含 IM、FR、权重和基于规则的 s/c 的处理后任务表	基于 O*NET 30.1 衍生 [?]]

4 模型构建与实现

4.1 职业选择作为建模决策

问题的前提要求从 STEM、技工和艺术领域各选择一个职业。我们没有将这一步骤视为临时假设 (主观选择), 而是明确地将职业选择建模为一个优化问题。这确保了后续关于 AI 驱动影响和教育建议的分析建立在可重现且数据驱动的框架之上。职业选择的核心目标不是所有职业的代表性, 而是解释性对比。具体而言, 三个职业的任务结构应当在与 GenAI 的交互方式上存在显著差异。除了机制对比外, 问题还明确强调数据驱动的推理以及后文的政策建议。因此, 所选职业同时需要有完备的数据支撑以及政策相关性。




图 1: 软件开发人员 (SOC 15-1252.00) 的任务级 IM-FR 暴露度。气泡大小编码归一化任务权重 w , 颜色编码基于规则的互补性 c , 边缘粗细反映基于规则的替代性 s 。字母标签映射到任务文本图例面板。

4.1.1 基于 O*NET 的职业特征参数客观化

为避免职业特征参数 $digit(x)$ 、 $physical(x)$ 和 $iprisk(x)$ 的主观赋值, 我们采用美国劳工部维护的 O*NET 职业数据库作为统一数据源, 详细的数据来源信息在第 3 节中总结。O*NET 基于专家调查和从业者反馈, 为每个职业提供大量数值量表描述符, 大多数指标自然地给出在 0–100 之间的实数上, 适合直接用于定量建模。

我们不试图为每个维度找到“唯一正确”的指标, 对于每个特征轴, 我们选择少量语义上直接对应且可下载的 O*NET 描述符, 并将其用作该轴的代理变量。

基于问题陈述和数据可用性约束, 我们识别出三个主导维度, 这些维度控制着 AI 影响在各职业间的异质性:

- **数字化程度** $digit(x)$: 核心任务可以以数字方式表示、自动化或增强的程度;
- **物理锚定** $physical(x)$: 任务执行对现场物理存在或与环境的手动交互的依赖程度;
- **知识产权和署名风险** $iprisk(x)$: 价值创造对作者身份、原创性和所有权的敏感程度。

每个候选职业 x 由一个归一化的三维特征向量表示

$$f(x) = (digit(x), physical(x), iprisk(x)) \in [0, 1]^3, \quad (1)$$

其中较高的值表示相应特征的存在更强。

对于分别从 STEM、技工和艺术类别中抽取的三个职业类别 (x_1, x_2, x_3) ，我们将两个职业之间的对比定义为其特征向量之间的欧几里得距离：

$$\Delta(x_i, x_j) = \|f(x_i) - f(x_j)\|_2. \quad (2)$$

定义数据可得性得分 $D(x_k)$ ，反映获取该职业相关数据的难易度与丰富度。整体选择目标公式化为

$$\max_{x_1 \in \text{STEM}, x_2 \in \text{Trade}, x_3 \in \text{Arts}} \left(\sum_{i < j} \Delta(x_i, x_j) + \lambda \sum_{k=1}^3 D(x_k) \right), \quad (3)$$

其中 λ 为权重系数，平衡解释性对比与经验可行性。

该公式不声称在所有可能职业中具有全局最优性。相反，它产生一个精心构建的高对比度职业集，在现实数据和时间约束下最大化分析清晰度。

归一化与可重现性 对于每个职业 x ，令 $v_m(x)$ 表示其在 O*NET 描述符 m 下的原始评分（0–100）。我们在整个职业集上应用最小-最大归一化：

$$z_m(x) = \frac{v_m(x) - \min_y v_m(y)}{\max_y v_m(y) - \min_y v_m(y)} \in [0, 1], \quad (4)$$

并对同一特征轴下的多个描述符取等权平均，得到 $digit(x)$ 、 $physical(x)$ 和 $iprisk(x)$ 。该过程完全基于公开可用数据和明确规则，确保参数值的可重现性和可审计性。

我们可视化了三维异质性及其二维投影，以验证所选职业在特征空间中占据不同区域（图 2 和图 3）。




图 2: 基于 O*NET 描述符（全局归一化）的所选 STEM、技工和艺术职业的三维异质性。




图 3: 异质性空间的二维投影；注释报告了剩余轴的值以增强可解释性（全局归一化）。

4.1.2 所选职业的修订与最终配置

在初始方案中，我们选择结构/土木工程师作为 STEM 职业。然而，在进一步检查三个职业在“任务结构”和“物理约束”维度上的分布后，我们发现该选择与技工职业（电工）在“物理锚定强度”轴上存

在一定相似性，可能削弱三个职业在机制空间中的对比度。

为最大化任务结构异质性并增强后续 GenAI 影响机制的可识别性，我们修订 STEM 端点，将其替换为**软件开发人员/软件工程师**。

该修订不改变原始选择模型的结构，仅调整职业端点在特征空间中的位置：软件开发人员具有极高的数字化程度和极低的物理锚定，从而显著增加其与电工在特征向量 $f(x)$ 中的距离，提高整体对比目标函数的值。

必须强调的是，我们不假设软件开发职业会被 GenAI 简单”替代”。相反，该职业更可能经历**任务结构重组**：编码和样板实现的比例降低，而需求澄清、系统架构设计、验证测试以及安全合规职责等任务的比例增加。正是这种从”执行导向型任务”到”验证和责任导向型任务”的转变，使软件开发成为研究 GenAI 影响机制的理想 STEM 端点。

完成此修订后，三个所选职业的最终配置如下：

- **STEM：软件开发人员/软件工程师**。数字化程度高，物理锚定低；GenAI 可直接介入核心任务，但主要表现为任务再分配而非职业消亡。
- **技工：电工**。物理锚定高，现场约束强；AI 主要作为规划、诊断和辅助工具，难以替代核心操作任务。
- **艺术：商业插画师/平面设计师**。知识产权和署名敏感性高；GenAI 直接影响产出形式和价值定价机制。

4.2 职业演化的模型选择

问题的第二个核心要求是构建一个数据驱动的未来职业演化模型。在引入正式方程之前，我们首先定义”未来演化”在可计算意义上的含义，然后系统地评估替代建模方法，使模型选择本身不成为隐式假设。

4.2.1 未来演化的可计算定义

我们将职业 i 的未来演化刻画为两个主要输出：

- **职业需求**：在快速、中速和慢速 GenAI 采纳情景下，就业需求 $E_i(t)$ 在 10 年期限内的时间演化；
- **任务结构**：职业内任务权重 $T_i(t)$ 的重新分配，表明哪些任务扩展、收缩或被重组。

该定义确保职业级结果源自任务级机制，而非直接施加。

4.2.2 候选建模方法比较

我们考虑三种代表性的职业演化建模方法：

方法 A：任务聚合影响模型 该方法将职业视为任务的加权组合。GenAI 驱动的替代和增强效应在任务级指定，然后使用任务权重聚合到职业级。大多数参数可从 O*NET 任务数据 [?] 和公开可用的 AI 暴露标尺 [?] 构建，提供透明性和可重现性。

方法 B：招聘信息时间序列模型 该方法从招聘信息中 AI 相关关键词和技能要求的趋势推断职业变化。虽然与市场信号紧密相关，但它存在识别挑战和高数据处理开销，不适合作为主要建模骨架。

方法 C：基于代理的模拟 基于代理的模型模拟企业、工人和教育机构之间的战略互动。尽管叙事丰富，但它们需要大量校准并引入实质性模型复杂性，这与严格页数限制下的透明性要求相冲突。

4.2.3 最终模型选择

基于上述比较，我们采用任务聚合影响模型（方法 A）作为主要框架。该选择的动机是：

- **机制清晰性**：职业变化明确源自任务级效应；
- **数据对齐**：关键参数基于公开可用的职业数据 [? ?]；
- **复杂性可控**：模型保持可解释性，适合情景和敏感性分析；
- **可迁移性**：框架可容易地扩展到其他职业或教育路径 [?]。

方法 B 保留用于潜在验证或补充分析，而方法 C 由于校准和透明性问题被排除在主要分析之外。

4.3 职业演化的任务聚合动态模型

在论证了任务聚合方法之后，我们现在展示其数学公式。我们采用一个最小化的任务到职业框架：GenAI 采纳 $A(t)$ 作为外生驱动因素进入，替代和增强在任务级指定，职业级净影响通过任务权重聚合得出，产生职业需求 $E_i(t)$ 的动态轨迹。

4.3.1 任务聚合与职业动力学

设职业 i 由任务 $j = 1, \dots, J_i$ 组成，权重为 w_{ij} ，满足

$$\sum_{j=1}^{J_i} w_{ij} = 1. \quad (5)$$

对于每个任务 j ，令 $s_{ij} \in [0, 1]$ 表示替代强度， $c_{ij} \in [0, 1]$ 表示增强（互补性）强度。定义职业级聚合效应为

$$\alpha_i = \sum_{j=1}^{J_i} w_{ij} s_{ij}, \quad \beta_i = \sum_{j=1}^{J_i} w_{ij} c_{ij}. \quad (6)$$

令 $E_i(t)$ 为职业 i 在时刻 t 的就业需求， g_i 捕获非 AI 因素的基线增长/衰减（从公共趋势估计或在情景分析下设为 0）。给定采纳轨迹情景族 $A(t) \in [0, 1]$ （快速/中速/慢速），我们将职业演化建模为

$$\frac{dE_i(t)}{dt} = E_i(t) \left(g_i + A(t) (\beta_i - \alpha_i) \right). \quad (7)$$

该公式确保职业结果源自任务级机制，支持可解释性、可重现性和数据驱动推理。

4.4 来自权威报告的 GenAI 能力维度评分：量表定义与证据叙述

为取代主观的“关键词标签”方法，我们采用来自权威评估和官方技术报告的能力评分。这些评分量化了 GenAI 在主要软件开发任务维度上的**替代**和**增强**能力，为将软件开发人员任务 DNA 映射到 (s, c) 输入提供可审计的依据。

4.4.1 量表定义

我们使用三个级别（低/中/高）表示 GenAI 能力，编码为 0.25、0.50 和 0.75：

- **低 (0.25)**: GenAI 在该任务类型上的自主能力有限，无法在没有人工干预的情况下可靠地交付满意结果；只能替代一小部分工作，但在人工监督下仍可提供协助。
- **中 (0.50)**: GenAI 表现中等，完成部分任务或提供有用建议，但仍需人工审查和协作；无法独立替代人工执行。
- **高 (0.75)**: GenAI 表现强劲，在许多子任务上接近专业人类水平；在适当约束和验证下，可处理大部分工作流程并提供显著增强，但仍不完美。

注意：0.25/0.50/0.75 的值是粗略的建模编码而非精确测量。所有级别都基于过去两年内发布的公开报告和对比实验。

4.4.2 按任务类型的能力证据（叙述性论证）

代码生成 替代：高 (0.75)；增强：高 (0.75)。 GenAI 在自动代码生成方面取得了强劲表现。OpenAI GPT-4 在 HumanEval 上达到 67.0% pass@1，远高于 GPT-3.5 的 48.1%；Anthropic Claude 2 在同一基准上达到 71.2%。这表明领先模型能正确解决超过一半的典型编码问题。Google CEO Sundar Pichai 表示，Google 约 25% 的新代码由 AI 工具生成，反映出显著的生产力提升：给定意图或注释，模型可以生成大量草稿代码并加速开发。对于简单模块，模型可以部分替代手动编码。然而，输出仍需人工审查和测试以减少逻辑错误和安全问题。总体而言，编码/实现是 GenAI 最具替代性和增强性的领域之一。

测试与验证 替代：中 (0.50)；增强：高 (0.75)。 GenAI 在生成测试用例和支持验证方面表现中等但在改进。研究报告显示，LLM 生成的单元测试可以达到与先进自动化工具相当的覆盖率，且通常更具可读性。例如，IBM 研究院在静态分析引导下的实验发现，基于 GPT 的系统可以生成具有竞争力覆盖率和缺陷检测能力的 Java/Python 单元测试，同时产生对开发者友好的测试。这支持了在常规函数级验证中的强劲增强。然而，生成的测试可能针对不相关场景或弱断言，需要人工审查；因此完全替代仍然困难。在实践中，GenAI 可以大幅减少手动测试编写并加速结果检查，而人类验证测试正确性。

调试与错误修复 替代：低 (0.25)；增强：中 (0.50)。 端到端调试仍是弱项：自主成功率相对较低，但辅助价值明显。2025 年 Microsoft Research 的一项研究报告显示，即使有调试器工具访问，最佳模型 (Anthropic Claude 3.7 Sonnet) 平均只解决了 300 个精选调试任务中的 48.4%，而其他模型约为 30%。这表明 GenAI 无法完全替代人工调试。局限性包括对调试信号的无效使用、策略选择不当以及缺乏逐步

推理痕迹。因此替代被评为低。同时，增强是明显的：有了日志或异常跟踪，模型可以提出有用的修复建议；在某些设置中，通过少样本演示的“自我调试”可提高约 2%–12% 的成功率。在实践中，GenAI 更多地作为助手而非独立的“修理工”。

系统设计/架构 替代：低 (0.25)；增强：中 (0.50)。架构和系统设计需要全局推理和负责任的权衡；GenAI 目前提供有限的支持。虽然没有单一的权威基准直接衡量系统设计能力，但模型通常产生看似合理但不完整的计划，遗漏关键约束或依赖错误假设。由于系统设计没有单一正确答案且需要负责任的决策，自主替代被评为低。尽管如此，增强可能有意义：模型可以起草设计文档、总结模式并头脑风暴替代方案，作为架构师的起点，提高讨论效率。

需求分析 替代：低 (0.25)；增强：中 (0.50)。需求工作需要深入的领域背景和歧义消解。GenAI 可以协助总结和结构化文本，但无法替代分析师。虽然专门评估有限，但相关任务如自然语言到形式化规范提供了证据：在 Spider（自然语言到 SQL）上，即使使用增强技术，GPT-4 的提升仅约 2%–3%，复杂查询仍具挑战性。这意味着对复杂、模糊需求的理解不可靠，因此替代为低。然而，增强是中等的：模型可以总结冗长文档、生成用户故事模板、提出澄清问题，并在人工监督下加速需求组织。

用户沟通与文档 替代：中 (0.50)；增强：高 (0.75)。GenAI 在语言生成方面表现出色，强力增强用户沟通和技术文档。GPT-4 和 Claude 2 等模型可以生成连贯的长篇草稿并遵守结构化格式（如 Markdown/JSON），实现 API 文档、手册和用户响应的快速起草。许多常规用户查询可以流畅且一致地回答。然而，准确性和幻觉风险仍然存在，特别是对于系统特定细节，因此完全替代人工沟通仍有风险；替代被评为中而增强被评为高。

4.5 任务影响的权威评估驱动重标记：从关键词标签到能力维度分配

为提高任务影响参数 (s_{ij}, c_{ij}) 的可辩护性和可重现性，我们放弃主观关键词标签，采用“**权威评估** → **能力维度** → **语义匹配** → **分段分配**”的重标记 workflow。核心思想是从官方评估报告中提取一组能力维度（如代码生成、调试、测试/验证、需求分析、系统设计、文档/沟通）的替代/增强级别，将每个软件开发人员任务映射到 1–2 个能力维度，然后在离散网格上分配 (s_j, c_j) 。

能力映射与可追溯性要求 对于每个任务 j ，定义其映射的能力集 dim_j （通常为 1–2 个维度以保持可解释性）。任务级替代和增强在离散量表上分配：

$$s_j, c_j \in \{0.25, 0.5, 0.75\}. \quad (8)$$

为满足“数据驱动”审计标准，每个任务必须携带**可追溯链**：(i) 映射的能力维度 dim_j ，(ii) 至少一个权威来源链接，(iii) 任务到维度匹配逻辑的简要说明。这确保 (s_j, c_j) 是可审查的而非基于研究者直觉。

语义阈值、异常报告与有限人工覆盖 由于语义匹配可能导致漏报和误报，匹配阈值被视为可控决策参数：阈值过高可能遗漏有效匹配；过低可能引入错误匹配。因此，重标记输出必须包含相似度得分和异常报告（如低相似度匹配、多维度分配冲突），并允许对少量语义模糊的高权重任务进行小规模人工覆盖列表。这保持了整体可重现性，同时防止少量错误标签偏移职业级聚合值 (α_i, β_i) 。

表 3: 来自权威评估报告的 GenAI 能力维度标尺（用于将软件开发人员任务映射到 s/c ）

任务类型	替代得分	增强得分	主要证据和支持
代码生成	高 (0.75)	高 (0.75)	GPT-4 在 HumanEval 上达到 67.0% pass@1 [?]。 Claude 2 达到 71.2% [?]。 Google 报告约 25% 的新代码由 AI 生成 [?]。 LLM 生成的单元测试可达到有竞争力的覆盖率和可读性。 研究表明在静态分析引导下测试质量更高 [?]。
测试与验证	中 (0.50)	高 (0.75)	仍需人工审查，因此替代保持中等。
调试与错误修复	低 (0.25)	中 (0.50)	Microsoft Research 报告即使有调试工具，端到端调试成功率低于 50%（最佳模型 48.4%） [?]。 提示修复建议有帮助，”自我调试”可提高准确率最多 12 个百分点 [?]。
系统设计	低 (0.25)	中 (0.50)	复杂架构需要综合推理；当前 GenAI 通常产生部分解决方案 [?]。 直接定量基准有限，但模型可以协助起草和文档以加速设计讨论 [?]。
需求分析	低 (0.25)	中 (0.50)	模型在 NL→spec 任务上的提升有限（如 Spider 上 2–3%） [?]。 然而，总结和问题生成可以提高需求获取和分析效率 [?]。
用户沟通与文档	中 (0.50)	高 (0.75)	Claude 2 等模型可以高效生成长篇结构化文档并回答常见问题 [?]。 准确性仍是问题；关键内容仍需人工验证 [?]。

4.6 将任务 DNA 聚合为职业级冲击参数：软件开发人员

本节将软件开发人员任务 DNA 从任务级输入 (w_{ij}, s_{ij}, c_{ij}) 聚合为职业级冲击参数 (α_i, β_i, μ_i)，这将输入演化方程 $\frac{dE_i(t)}{dt} = E_i(t)(g_i + A(t)(\beta_i - \alpha_i))$ 。

4.6.1 Top- N 可用性与聚合

在实践中，O*NET 任务评分可能对某些任务缺失。因此我们采用”Top- N_i 可用任务”策略：对于职业 i ，我们只保留具有足够评分以构建权重的任务，并重新归一化使得 $\sum_{j=1}^{N_i} w_{ij} = 1$ 。职业级替代压力、增强收益和净方向定义为

$$\alpha_i = \sum_{j=1}^{N_i} w_{ij} s_{ij}, \quad \beta_i = \sum_{j=1}^{N_i} w_{ij} c_{ij}, \quad \mu_i = \beta_i - \alpha_i. \quad (9)$$

4.6.2 可解释性分解：Top- K 贡献下界

为增强可解释性，我们分解高权重任务的贡献。定义部分和

$$\alpha_i^{(K)} = \sum_{j \in \text{Top-}K} w_{ij} s_{ij}, \quad \beta_i^{(K)} = \sum_{j \in \text{Top-}K} w_{ij} c_{ij}. \quad (10)$$

对于当前可用的 Top-5 样本， $\sum_{j \in \text{Top-5}} w_{ij} = 0.360897$ ，部分贡献 $\alpha_i^{(5)} = 0.1804485$ 和 $\beta_i^{(5)} = 0.2153186$ ，表明高权重任务（通常是测试/维护/需求/协作）将主导聚合冲击。

4.6.3 评分规则的有效性检验：避免近常数 s/c

如果许多任务共享相同的离散得分（如 0.50），则 α_i 和 β_i 变得弱区分性，削弱机制解释。因此我们检验离散网格 $\mathcal{G} = \{0, 0.25, 0.5, 0.75, 1\}$ 上的权重质量集中度：

$$p_s(g) = \sum_{j: s_{ij}=g} w_{ij}, \quad p_c(g) = \sum_{j: c_{ij}=g} w_{ij}, \quad g \in \mathcal{G}, \quad (11)$$

使用集中度和归一化熵：

$$C_s = \max_{g \in \mathcal{G}} p_s(g), \quad C_c = \max_{g \in \mathcal{G}} p_c(g), \quad (12)$$

$$H_s = -\frac{\sum_{g \in \mathcal{G}} p_s(g) \ln p_s(g)}{\ln |\mathcal{G}|}, \quad H_c = -\frac{\sum_{g \in \mathcal{G}} p_c(g) \ln p_c(g)}{\ln |\mathcal{G}|}. \quad (13)$$

高 C_s 或低 H_s 标志得分压缩并触发最小校准。

4.6.4 最小校准：带有限人工审查的类别默认值

为避免重新收集数据，我们仅通过一小组任务类别校准 s/c ，同时保持任务列表和权重 w_{ij} 不变。令 $\kappa(j)$ 将每个任务映射到一个粗类别（如需求/利益相关者、编码/实现、测试/验证/安全、监控/运维），并带有默认 (s, c) 对。然后我们仅手动审查少量高权重任务并记录简要证据说明，在保持可重现性和透明性的同时提高 (α_i, β_i) 的可识别性。

5 权威重标记后的机制力量检验与职业级聚合（软件开发人员）

在将 (s_j, c_j) 从主观关键词标签升级为“权威评估 → 能力维度 → 语义匹配 → 分段分配”流程后，我们必须验证**机制力量**： (s_j, c_j) 的任务级异质性应足够充分，且任务权重 w_j 不应将 (α, β) 坍缩为单一默认驱动的结果。否则，即使是权威来源也会在演化模型中产生弱可识别性。

5.1 职业级冲击聚合值

对于可用任务集（大小为 N ，允许 $N < 20$ ），重新归一化使得 $\sum_{j=1}^N w_j = 1$ ，我们定义

$$\alpha = \sum_{j=1}^N w_j s_j, \quad \beta = \sum_{j=1}^N w_j c_j, \quad \mu = \beta - \alpha. \quad (14)$$

5.2 诊断：异质性与有效多样性

(1) 加权方差（异质性）

$$\text{Var}_w(s) = \sum_{j=1}^N w_j (s_j - \alpha)^2, \quad \text{Var}_w(c) = \sum_{j=1}^N w_j (c_j - \beta)^2. \quad (15)$$

低方差表明得分压缩或映射规则过度收敛，削弱可识别性。

(2) 加权层级直方图（避免单层级主导） 令 $\mathcal{G}_{LMH} = \{0.25, 0.5, 0.75\}$ 。定义层级权重质量

$$h_s(g) = \sum_{j: s_j=g} w_j, \quad h_c(g) = \sum_{j: c_j=g} w_j, \quad g \in \mathcal{G}_{LMH}. \quad (16)$$

较大的 $\max_g h_s(g)$ 或 $\max_g h_c(g)$ 标志默认驱动的坍塌。

(3) 能力维度权重质量（避免权重集中） 对于每个任务 j ，令 dim_j 为其映射的维度集（1–2 个维度）。如果多重映射，令 π_{jd} 将任务 j 分配到维度 d ，满足 $\sum_{d \in \text{dim}_j} \pi_{jd} = 1$ 。维度权重质量为

$$m(d) = \sum_{j=1}^N w_j \pi_{jd}. \quad (17)$$

高 $\max_d m(d)$ 表明尽管名义覆盖广泛，但有效多样性低。

5.3 工程阈值与行动 ($E(t)$ 前的门控)

我们使用工程阈值作为门控，决定是否进入情景演化：

$$\text{Var}_w(s) \geq \varepsilon_s, \quad \text{Var}_w(c) \geq \varepsilon_c, \quad \max_g h_s(g) \leq \eta_s, \quad \max_d m(d) \leq \eta_d, \quad (18)$$

默认值为 $\varepsilon_s = \varepsilon_c = 0.005$ ， $\eta_s = 0.70$ ， $\eta_d = 0.60$ 。违反意味着高机制风险，需要在推进到情景驱动的 $E(t)$ 动力学之前，对层级划分或维度到 (s, c) 映射进行优化（无需改变 w_j ）。

6 一致性检验与演化方程的实例化：软件开发人员的 (α, β, μ)

在通过“权威评估 → 能力维度 → 语义匹配 → 离散层级 (s, c) ”对任务影响进行重标记后，我们将任务 DNA 聚合回职业级冲击参数 (α, β, μ) 并首先进行一致性检验，防止下游动力学依赖于错误实现的净冲击项。

6.1 聚合值与一致性检验

根据定义，

$$\mu = \beta - \alpha. \quad (19)$$

给定预览值 $\alpha = 0.379113$ 和 $\beta = 0.629112$ ，我们必须有

$$\mu = 0.629112 - 0.379113 = 0.249999. \quad (20)$$

然而，预览 JSON 报告 $\mu = 0.504112$ ，这与模型定义相矛盾。因此，在将 μ 用作 $E(t)$ 的输入之前，聚合输出必须明确声明 `mu_definition` 并修正实现；否则，演化推断将系统性地产生偏差。

6.2 机制力量（异质性）检验：无得分坍塌

使用加权方差

$$\text{Var}_w(s) = \sum_{j=1}^N w_j (s_j - \alpha)^2, \quad \text{Var}_w(c) = \sum_{j=1}^N w_j (c_j - \beta)^2, \quad (21)$$

预览报告 $\text{Var}_w(s) = \text{Var}_w(c) = 0.015608$ ，超过工程阈值（如 0.005）。这表明重标记的 (s, c) 保留了足够的异质性；机制可识别性未被坍塌。

6.3 低置信度任务的最小敏感性（上界论证）

对于低置信度匹配（如 `task_id=21666`，权重 $w = 0.05434$ ），可通过最坏情况边界论证稳健性。由于层级为 $\{0.25, 0.5, 0.75\}$ ，每任务层级最大摆动为 0.50 ($0.25 \leftrightarrow 0.75$)，因此

$$\Delta_{\max}(\alpha) \leq w \cdot 0.50 = 0.05434 \times 0.50 = 0.02717, \quad (22)$$

类似地 $\Delta_{\max}(\beta) \leq 0.02717$ 。两个轻量级情景（删除该任务；重映射到次优维度）足以支撑可辩护的敏感性陈述。

6.4 修正 μ 后进入职业演化

一旦 μ 被修正，演化方程变为

$$\frac{dE(t)}{dt} = E(t)(g + A(t)\mu), \quad (23)$$

其中 $A(t)$ 是采纳情景（快速/中速/慢速）， g 是非 AI 基线（公共趋势估计或在相对指数约定下设为 0）。相对尺度具有闭式解

$$\frac{E(t)}{E(t_0)} = \exp\left(\int_{t_0}^t (g + A(\tau)\mu) d\tau\right). \quad (24)$$

因此，在 μ 定义一致且 $A(t)/g$ 明确指定之前，我们不推进到 $E(t)$ 情景曲线，避免不可计算的叙述。

7 任务级功能需求模型与职业重新定义

7.1 任务级功能需求模型（替代职业级岗位需求）

7.1.1 建模目标与符号

我们不预测职业级岗位数量，而是预测在 GenAI 采纳下职业的任务组成如何演化，以及与每个任务相关的人力劳动需求如何随时间变化。核心主张是，当一个职业的基线任务束中足够大的部分变得

可忽略不计时，该职业的性质已经改变，应被重新定义（确切的新职位名称不是模型的核心）。

考虑一个职业 i 分解为任务 $j = 1, \dots, J_i$ 。对于每个任务，我们假设以下输入已经通过任务 DNA 和权威重标记流程构建完成：

- 基线任务权重 $w_{ij}(0)$ ，满足 $\sum_j w_{ij}(0) = 1$ 。
- 替代分数 $s_{ij} \in [0, 1]$ ：GenAI 能够在多大程度上减少任务 j 的人力努力。
- 增强分数 $c_{ij} \in [0, 1]$ ：GenAI 能够在多大程度上扩展与任务 j 相关的功能范围/需求。
- 采纳曲线 $A(t) \in [0, 1]$ ：时刻 t 的 GenAI 采纳比例/强度（情景驱动）。

我们引入四个状态变量：

$Q_i(t)$ ：职业 i 的整体功能输出需求指数，
 $\ell_{ij}(t)$ ：任务 j 的劳动强度（单位输出的人力努力），
 $w_{ij}(t)$ ：时变任务劳动份额（任务结构），
 $D_{ij}(t)$ ：任务 j 的人力劳动需求指数

直观上， s_{ij} 控制人力努力对任务变得不必要的速度（自动化渠道），而 c_{ij} 控制整体功能需求可以扩张的程度（规模化渠道）。这些是不同的机制，不会强制抵消。

7.1.2 双渠道动力学：自动化与规模化

(a) 自动化渠道：替代降低劳动强度。 我们假设随着 GenAI 采纳增加，替代分数更高的任务每单位输出所需的人力努力更少：

$$\frac{d \ln \ell_{ij}(t)}{dt} = -\kappa_s A(t) s_{ij}, \quad \kappa_s > 0. \quad (25)$$

闭式解为

$$\ell_{ij}(t) = \exp\left(-\kappa_s s_{ij} \int_0^t A(\tau) d\tau\right). \quad (26)$$

参数含义（通俗语言）。 κ_s 是替代速度系数。更大的 κ_s 意味着在相同的 $A(t)$ 和 s_{ij} 下人力努力下降更快。

(b) 任务结构更新：职业内部重新分配。 自动化改变了职业的内部组成。我们形成未归一化份额并重新归一化：

$$\tilde{w}_{ij}(t) = w_{ij}(0) \ell_{ij}(t), \quad w_{ij}(t) = \frac{\tilde{w}_{ij}(t)}{\sum_k \tilde{w}_{ik}(t)}. \quad (27)$$

解释。高度自动化的任务（小的 $\ell_{ij}(t)$ ）失去份额；剩余的人力劳动转移到更难替代的任务。

(c) 规模化渠道（可选）：增强扩展整体功能需求。 为了捕捉生产力工具可能增加组织选择完成的工作总量这一可能性，我们建模整体功能需求指数：

$$\frac{d \ln Q_i(t)}{dt} = g_i + \kappa_c A(t) \bar{c}_i, \quad (28)$$

其中

$$\bar{c}_i = \sum_j w_{ij}(0) c_{ij}. \quad (29)$$

参数含义（通俗语言）。 g_i 是功能需求的基线（非 GenAI）增长；如果想避免宏观假设，可设 $g_i = 0$ 。 $\kappa_c \geq 0$ 是增强对需求的放大因子。 $\bar{c}_i$ 总结了职业在基线组成下的增强潜力。（一种变体用 $w_{ij}(t)$ 替代 $w_{ij}(0)$ ；我们使用 (29) 以简化和参数稳定性。）

(d) 任务劳动需求指数。 我们通过当前任务结构将功能需求分配给任务：

$$D_{ij}(t) = Q_i(t) w_{ij}(t), \quad \frac{D_{ij}(t)}{D_{ij}(0)} = \frac{Q_i(t) w_{ij}(t)}{w_{ij}(0)}. \quad (30)$$

解释。即使整体需求 $Q_i(t)$ 增长，如果任务份额 $w_{ij}(t)$ 因替代而崩溃，任务的人力需求仍可能缩减。

7.1.3 采纳情景 $A(t)$

我们使用简约、可解释的逻辑斯蒂族：

$$A(t) = \frac{1}{1 + \exp(-k(t - t_0))}. \quad (31)$$

参数含义（通俗语言）。 k 控制陡峭程度（采纳加速的速度）。 t_0 是拐点时间，此时采纳达到 50%。我们通过选择三对 (k, t_0) 定义三种情景（快速/中速/慢速）；这保持了驱动因子数量较少，同时支持敏感性比较。

7.1.4 职业重新定义触发器（工作本质变化）

我们通过任务消亡和任务结构漂移形式化“工作本质变化”。两个标准中任一标准均可触发重新定义。

(a) 消亡质量（任务需求变得可忽略不计）。 当任务的人力需求指数降至其基线的一小部分以下时，该任务被视为功能上可忽略不计：

$$\frac{D_{ij}(t)}{D_{ij}(0)} < \varepsilon, \quad (32)$$

其中 $\varepsilon \in (0, 1)$ （例如， $\varepsilon = 0.05$ ）。定义基线加权的消亡质量：

$$M_{\text{drop}}(t) = \sum_{j: D_{ij}(t)/D_{ij}(0) < \varepsilon} w_{ij}(0). \quad (33)$$

我们认为职业在本质上已改变，当且仅当

$$M_{\text{drop}}(t) \geq \theta, \quad (34)$$

其中 $\theta \in (0, 1)$ （例如， $\theta = 0.30$ ）是在触发重新定义之前必须变得可忽略不计的基线任务质量份额。

(b) 任务结构漂移（分布变化）。即使没有许多任务完全变得可忽略不计，如果职业的任务份额分布发生足够大的变化，该职业也可能在性质上变得不同。令 $w_i(t)$ 表示向量 $(w_{i1}(t), \dots, w_{iJ_i}(t))$ 。我们使用 Jensen–Shannon 散度作为对称、有界的漂移度量：

$$\text{JS}(w_i(t) \| w_i(0)) \geq \delta, \quad (35)$$

其中 $\delta > 0$ 是为稳健性选择的保守阈值。

触发时间。定义

$$t^* = \inf \{t : M_{\text{drop}}(t) \geq \theta \text{ 或 } \text{JS}(w_i(t) \| w_i(0)) \geq \delta\}. \quad (36)$$

我们报告 t^* 是否存在于预测范围内，并将其用作职业应被重新定义的基于模型的证据。

7.1.5 计算算法（可重现流程）

对于每个职业 i 和每个采纳情景：

1. 从 (31) 计算 $A(t)$ ，以及累积采纳积分 $I(t) = \int_0^t A(\tau) d\tau$ （数值求积）。
2. 使用 (26) 计算劳动强度 $\ell_{ij}(t)$ 。
3. 通过 (27) 更新任务份额 $w_{ij}(t)$ 。
4. 使用 (28) 求解 $Q_i(t)$ 。如果避免宏观假设，设 $g_i = 0$ 和 $\kappa_c = 0$ ，使得 $Q_i(t) \equiv 1$ 。
5. 从 (30) 计算任务劳动需求指数 $D_{ij}(t)$ 。
6. 评估重新定义标准 (34) 和 (35)，如果存在则通过 (36) 获得 t^* 。

7.1.6 参数表（待实例化）

表 4 总结了需要指定的参数。我们优先考虑可解释性和低驱动因子数量。

表 4: 任务级模型参数及通俗语言含义。

参数	典型范围/设置	含义（通俗语言）
k, t_0	情景特定	采纳速度和 50% 采纳时间
κ_s	> 0	替代降低人力努力的速度
g_i	0（默认）	基线功能需求增长（非 GenAI）
κ_c	0 或 > 0	增强扩展总需求的强度
ε	例如 0.05	”可忽略任务” 阈值（基线的 5%）
θ	例如 0.30	重新定义职业所需的消亡质量
δ	例如 0.10–0.30	任务份额漂移阈值（JS 散度）

7.2 可视化方案

本节定义展示任务结构变化和重新定义证据所需的图表。

图 4: 由 (31) 定义的 GenAI 采纳情景 $A(t)$ (快速/中速/慢速)。拐点时间 t_0 标记 50% 采纳。

7.2.1 图表模板

图 1: 采纳情景 $A(t)$ 。

图 5: 职业 i 中基线权重最高的前 K 个任务在各采纳情景下的相对任务劳动需求轨迹 $D_{ij}(t)/D_{ij}(0)$ 。此图直接显示哪些任务变得可忽略不计, 哪些任务仍然核心。

图 2: 顶部任务的任务劳动需求轨迹。

图 6: 时变任务结构 $w_{ij}(t)$ (堆叠面积图或热图)。此图可视化由 (27) 驱动的替代引起的职业内部重新分配。

图 3: 任务结构漂移 $w_{ij}(t)$ 。

图 7: 随时间的重新定义证据: 消亡质量 $M_{\text{drop}}(t)$ 及阈值 θ , 以及 (可选) $\text{JS}(w_i(t)||w_i(0))$ 及阈值 δ 。最早的交叉点在 (36) 中定义 t^* 。

图 4: 重新定义证据和触发时间 t^* 。

7.3 敏感性与稳健性

7.3.1 低置信度任务敏感性

由于与权威评估维度的语义匹配较弱, 某些任务可能具有低置信度的 (s_{ij}, c_{ij}) 分配。对于每个标记的任务, 我们运行两种有界敏感性情况:

- **删除:** 从集合中移除该任务, 并重新归一化剩余的 $w_{ij}(0)$ 。
- **重新标记:** 保持 $w_{ij}(0)$, 但用第二最佳可接受映射 (或保守界限) 替换 (s_{ij}, c_{ij}) 。

我们报告以下变化: (i) 重新定义是否在范围内发生, (ii) 触发时间 t^* , 以及 (iii) 消亡质量曲线 $M_{\text{drop}}(t)$ 。

7.3.2 关键参数敏感性

我们仅变化最小、高杠杆的参数集以避免过拟合:

- κ_s (替代速度): 慢速/中速/快速值。
- κ_c (规模化开/关): $\kappa_c = 0$ 与正值。
- 阈值 $(\varepsilon, \theta, \delta)$: 保守与激进设置。

对于每种组合, 我们总结定性结论的稳定性 (哪些任务变得可忽略不计, 以及是否/何时触发重新定义)。

7.4 输出摘要模板（每个职业）

对于每个职业和每个采纳情景，我们呈现：

1. **任务需求结果：**按 $D_{ij}(15)/D_{ij}(0)$ 排名的任务列表，突出显示低于 ε 的任务。
2. **任务结构变化：** $w_{ij}(t)$ 的可视化以及漂移度量 $JS(w_i(t)||w_i(0))$ 。
3. **重新定义决策：**(34) 或 (35) 中的标准是否满足，以及触发时间 t^* （如适用）。

8 仿真结果与敏感性分析

通过图表提供可视化数据。讨论模型的稳健性。敏感性分析对于获得 Meritorious 或 Outstanding 奖项至关重要。

9 讨论：优势与不足

9.1 优势

预测精度高；适用于高维数据。

9.2 不足

大规模矩阵的计算复杂度较高。

10 结论

总结研究发现并提供可操作的建议。

Appendices

附录 A Python 实现代码

```
1 def model_solver(data):  
2     # 核心数学逻辑  
3     return results
```

AI 工具使用报告

1. 对话可追溯性

对于每次使用，提供准确的**提示词/查询**和**原始 AI 输出**（或具有代表性的摘录）。仅当 AI 仅用于翻译时才可省略完整日志；在这种情况下，需注明**工具名称和版本**。

- **示例—提示词：**”为模型部分建议一个大纲。” **输出（摘录）：**”1. 陈述假设；2. 定义符号；3. 推导主要方程...”
- **仅使用翻译的团队：**声明工具名称和版本（如 DeepL 4.2、ChatGPT-4）；无需提供完整的提示词日志。

2. 分阶段声明

说明 AI 在哪些阶段被使用，例如：

- 初始构思/头脑风暴
- 代码修正/调试
- 翻译/文字编辑

标注每个阶段是否使用，并注明每个阶段使用的工具。

3. 风险验证

描述团队如何检查**幻觉**和**错误引用**：例如，对关键声明进行人工事实核查、验证参考文献、交叉检验公式和代码。如果仅用于翻译，请声明没有将实质性技术内容委托给 AI 处理。